x alphabétique75section*.62

Université Abdelmalek Essaâdi
Ecole Nationale des Sciences Appliquées
Tanger

PROJET DE FIN D'ANNÉE

Comparaison entre les modèles de Markov et les réseaux de neurones convolutifs CNN pour la détection automatique des défauts dans les systèmes industriels à l'aide de l'intelligence artificielle et de l'IOT

RAPPORT DE STAGE

SMART **AUTOMATION**
TECHNOLOGIES

Réalisé par :

ANDRIASAHY Tsikomia Scidelo

Encadrant entreprise :

Mr. Said Amghar

Période du stage :	du 01/07/2026 à 31/08/2026
Effectué à :	SMART AUTOMATION TECHNOLOGIES (SAT)
Filière :	Génie des Systèmes Electroniques et Automatiques (GSEA)
Niveau :	2ème année cycle d'ingénieur

Année Universitaire : 2025/2026

Avant-propos

Le présent rapport clôture ma deuxième année du cycle d'ingénieur au sein de la filière Génie des Systèmes Électroniques et Automatiques (GSEA) à l'École Nationale des Sciences Appliquées de Tanger (ENSAT). Il formalise les travaux menés lors de mon stage d'été au sein de la société Smart Automation Technologies (SAT), articulés autour d'une problématique au confluent de l'automatique, de l'intelligence artificielle et du diagnostic industriel : la détection précoce d'anomalies sur les moteurs asynchrones par thermographie infrarouge. Face à la complexité des signatures radiométriques en milieu opérationnel, ce projet est né d'une volonté de confronter deux visions méthodologiques complémentaires : la robustesse explicable de la physique statistique via les modèles markoviens (MRF, HMM, chaînes absorbantes), et la puissance discriminante de la vision par ordinateur par réseaux convolutifs (CNN, U-Net). Au-delà des performances métriques brutes, notre ligne directrice a consisté à préserver en permanence le sens physique de la mesure et à questionner l'intégrité de la chaîne de décision. Ce document se veut une passerelle transparente entre la recherche appliquée et l'ingénierie opérationnelle. Il s'adresse aussi bien au praticien de la maintenance conditionnelle désireux de comprendre la modélisation formelle du risque, qu'au roboticien ouomaticien explorant l'intégration d'algorithmes prédictifs en périphérie de réseau (Edge computing). Puisse ce modeste travail apporter un éclairage utile sur les synergies fécondes entre formalisme probabiliste et apprentissage profond.

Les listes de figures, de tableaux, d'abréviations et de symboles regroupées en tête d'ouvrage permettent de naviguer aisément parmi les notations retenues. Le système proposé est conçu comme un outil d'**aide à la décision technique**, destiné à assister l'expertise humaine sans s'y substituer.

Dédicaces

Je dédie ce modeste travail à celles et ceux dont l'amour, la présence et les encouragements ont accompagné mon parcours.

À mes très chers parents,
TSIKOMIA AmaÏde Arsan Miriarison et Joanolisoa Tahina Estelle,

Pour votre amour inconditionnel, les sacrifices consentis et le soutien indéfectible que vous m'avez apporté tout au long de mes études. Aucune dédicace ne saurait traduire pleinement ma gratitude ni le profond respect que je vous porte. Puisse ce travail être le témoignage de ma reconnaissance et de mon affection éternelles.

À ma chère tante, RALOHOTSY Marie Francine,

Pour ta présence bienveillante, tes précieux conseils et ton affection constante. Tes encouragements ont été un soutien précieux à chaque étape de mon parcours.

À mes frères et sœurs,

Pour notre complicité, votre soutien moral et les moments de joie partagés, qui ont donné force et légèreté à ces années d'études.

À toute ma famille,

Pour votre affection, vos prières et votre présence, qui m'ont accompagné et encouragé à persévérer.

À mes chers amis,

Pour votre soutien, votre disponibilité et cet esprit d'entraide qui a rendu ces années de formation plus riches et plus humaines.

À toutes celles et à tous ceux qui ont contribué, de près ou de loin, à la réussite de ce projet, je dédie le fruit de mes efforts avec une sincère reconnaissance.

Remerciements

Je tiens à exprimer ma sincère gratitude à mon encadrant, **M. Said Amghar**, pour son accompagnement, ses orientations et ses conseils tout au long de ce projet.

J'adresse également mes remerciements à l'ensemble de l'équipe pédagogique de l'**École Nationale des Sciences Appliquées de Tanger (ENSAT)**. La qualité de la formation reçue, la disponibilité des enseignants et leur soutien continu ont constitué des appuis essentiels à la réalisation de cette expérience et à la consolidation de mes compétences.

Je remercie chaleureusement l'ensemble du personnel de **SMART AUTOMATION TECHNOLOGIES (SAT)** pour son accueil, son amabilité et sa coopération. La disponibilité des équipes, leur ouverture d'esprit et la qualité des échanges ont fait de ce stage une expérience aussi agréable qu'enrichissante, sur les plans professionnel et humain.

Mes remerciements s'adressent aussi à toutes les personnes qui ont contribué, directement ou indirectement, à l'avancement de ce travail. Je remercie notamment les équipes de recherche qui rendent accessibles leurs jeux de données, leurs publications et leurs outils, et permettent ainsi l'apprentissage et la comparaison des méthodes.

Enfin, j'exprime ma profonde reconnaissance à ma famille et à mes amis pour leur soutien indéfectible tout au long de mon parcours académique et professionnel. Leurs encouragements constants, leur patience et leur présence ont été essentiels pour mener ce stage et ce projet à leur terme.

Résumé

Ce mémoire compare les modèles de Markov et les réseaux de neurones convolutifs (CNN) pour la détection automatique des défauts industriels. La thermographie de moteurs asynchrones constitue le cas d'application, dans une perspective de surveillance par l'intelligence artificielle et l'Internet des objets (IoT). L'objectif est d'articuler trois niveaux d'analyse : la classification d'un état de fonctionnement, la localisation spatiale d'une région à surveiller et le suivi temporel de son évolution.

La première partie exploite un jeu de 488 thermogrammes répartis entre six classes combinant état du roulement et niveau de charge. Cinq réseaux convolutifs directs et vingt associations entre extracteurs convolutifs et classifieurs classiques sont comparés. Sur une validation interne de 100 images, MobileNetV2 atteint une exactitude de 94 %, tandis que DenseNet121 associé à KNN ou Random Forest atteint 98 %. La forte proximité entre images d'entraînement et de validation limite toutefois la portée de ces résultats.

La seconde partie s'appuie sur des séquences thermiques et des annotations spatiales pour étudier deux approches complémentaires : segmentation MRF, descripteurs et suivi HMM d'une part ; U-Net, classification contextuelle et prise en compte de la durée d'autre part. Le risque de premier passage vers un état critique est formulé à un horizon fini. Les résultats spatiaux disponibles indiquent un Dice de 0,9851 pour le U-Net, sous réserve de la définition des annotations et du protocole de séparation.

L'analyse souligne le rôle déterminant de la calibration radiométrique, de la disponibilité du contexte, de l'indépendance des essais et de la distinction entre une formulation théorique et son implémentation. L'intégration IoT demeure une perspective de déploiement. Le système étudié constitue une **aide à la décision de maintenance**, et non un substitut aux protections de la machine ou à l'expertise humaine.

Mots-clés : modèles de Markov ; IoT ; thermographie infrarouge ; moteur asynchrone ; maintenance prévisionnelle ; CNN ; U-Net ; MRF ; HMM ; HSMM ; chaîne absorbante ; calibration.

Abstract

This dissertation compares Markov models and convolutional neural networks (CNNs) for automatic industrial fault detection. Infrared thermography of induction motors provides the application case, within the scope of artificial intelligence and Internet of Things (IoT) monitoring. It connects three levels of analysis: operating-state classification, spatial localisation of a region of interest, and temporal monitoring of its evolution.

The first part uses 488 thermograms grouped into six classes combining bearing condition and load level. Five direct convolutional networks and twenty hybrid feature-extractor/classifier combinations are compared. On an internal validation set of 100 images, MobileNetV2 achieves 94% accuracy, while DenseNet121 combined with KNN or Random Forest reaches 98%. Strong similarity between neighbouring training and validation images nevertheless limits the generalisability of these results.

The second part investigates complementary approaches using thermal sequences and spatial annotations: MRF segmentation, interpretable descriptors and HMM tracking on the one hand; U-Net segmentation, contextual classification and duration-aware tracking on the other. The probability of first reaching a critical state is formulated over a finite horizon. Available spatial results report a U-Net Dice score of 0.9851, whose interpretation depends on the annotation target and data-splitting protocol.

The analysis highlights radiometric calibration, contextual information, independent experiments and the distinction between a theoretical model and its implementation. IoT integration remains a deployment perspective. The proposed framework supports **maintenance decision-making**; it does not replace machine protection systems or human expertise.

Keywords: Markov models; IoT; infrared thermography; induction motor; predictive maintenance; CNN; U-Net; MRF; HMM; HSMM; absorbing Markov chain; calibration.

Liste des abréviations, sigles et acronymes

Sigle	Signification
AI / IA	Artificial Intelligence / intelligence artificielle
AUPRC	Area Under the Precision–Recall Curve : aire sous la courbe précision–rappel
AUROC	Area Under the Receiver Operating Characteristic Curve : aire sous la courbe ROC
BCE	Binary Cross-Entropy : entropie croisée binaire
BMP	Bitmap : format de fichier image matricielle
BNUT	Babol Noshirvani University of Technology
CFL / CML / CNL	Corroded Full / Medium / No Load : roulement corrodé à pleine charge, charge moyenne ou à vide
CNN	Convolutional Neural Network : réseau de neurones convolutif
CSV	Comma-Separated Values : fichier tabulaire de valeurs séparées
ECE	Expected Calibration Error : erreur de calibration estimée
HFL / HML / HNL	Healthy Full / Medium / No Load : roulement sain à pleine charge, charge moyenne ou à vide
HMM	Hidden Markov Model : modèle de Markov caché
HSMM	Hidden Semi-Markov Model : modèle semi-markovien caché
ICM	Iterated Conditional Modes : modes conditionnels itérés
IoU	Intersection over Union : intersection sur union
IR	Infrarouge
KNN	K-Nearest Neighbours : méthode des K plus proches voisins
MC	Monte Carlo
ML	Machine Learning : apprentissage automatique
MRF	Markov Random Field : champ aléatoire de Markov
NETD	Noise Equivalent Temperature Difference : différence de température équivalente au bruit
RBF	Radial Basis Function : fonction à base radiale
RF	Random Forest : forêt aléatoire
RGB / RVB	Red, Green, Blue / rouge, vert, bleu
ROI	Region of Interest : région d'intérêt
RUL	Remaining Useful Life : durée de vie utile restante
SVM	Support Vector Machine : machine à vecteurs de support
U-Net	Réseau de segmentation à architecture encodeur–décodeur en U
XGBoost	Extreme Gradient Boosting : méthode d'arbres renforcés par gradient

Sigles institutionnels et intégration numérique

Sigle	Signification
EcoDID	Écosystème digital, intelligent et décisionnel
ENSAT	École Nationale des Sciences Appliquées de Tanger
IoT	Internet of Things : Internet des objets
IT	Information Technology : technologies de l'information
R&D	Recherche et développement
SARL	Société à responsabilité limitée
SAT	Smart Automation Technologies

Liste des symboles et des unités

Grandeurs thermiques et spatiales

Symbole	Signification	Unité
T, T_s, T_a	Température, température de surface, température ambiante	K ou °C selon indication
T_{refl}	Température apparente réfléchie	K ou °C
ΔT	Écart de température	K ou °C
ε	Émissivité de la surface	sans unité
τ_a	Transmission atmosphérique	sans unité
λ	Longueur d'onde	m
ν	Fréquence du rayonnement	Hz
h_{P}	Constante de Planck	$\text{J}\,\text{s}$
c	Vitesse de la lumière	$\text{m}\,\text{s}^{-1}$
k_{B}	Constante de Boltzmann	$\text{J}\,\text{K}^{-1}$
σ_{SB}	Constante de Stefan–Boltzmann	$\text{W}\,\text{m}^{-2}\,\text{K}^{-4}$
M	Exitance radiative totale	$\text{W}\,\text{m}^{-2}$
L_λ	Luminance spectrale, par unité de longueur d'onde	$\text{W}\,\text{m}^{-3}\,\text{sr}^{-1}$
ρ, c_p, k	Masse volumique, capacité thermique massique, conductivité	$\text{kg}\,\text{m}^{-3}$; $\text{J}\,\text{kg}^{-1}\,\text{K}^{-1}$; $\text{W}\,\text{m}^{-1}\,\text{K}^{-1}$
q_v	Puissance thermique volumique	$\text{W}\,\text{m}^{-3}$
$I(p), y_p$	Valeur d'image et intensité normalisée au pixel p	unité instrumentale ou sans unité
$\Omega, \mathcal{N}(p)$	Domaine de l'image et voisinage du pixel p	ensembles
x_p	Étiquette spatiale du pixel p	sans unité
E, β	Énergie de segmentation et poids de régularisation	sans unité dans le modèle
μ_k, σ_k	Moyenne et écart-type de l'intensité de classe k	unité de l'intensité
σ_s, σ_r	Échelles spatiale et radiométrique du filtre bilatéral	pixel ; unité de l'intensité
A, r_A	Aire du masque et fraction de la ROI occupée	pixel ; sans unité
$\bar{x}, \bar{y}$	Coordonnées du barycentre	pixel
H	Indicateur de santé normalisé	sans unité

Modèles, états et probabilités

Symbole	Signification	Unité
S_t, t	État caché et indice temporel	état ; pas d'acquisition
P, Q, R	Transition, sous-matrice transitoire et transitions vers l'absorption	sans unité
α_t	Distribution filtrée des états au temps t	sans unité
$N = (I - Q)^{-1}$	Matrice fondamentale : nombre moyen de visites	pas / visites
$h, r_t(h)$	Horizon de projection et risque à cet horizon	pas ; sans unité
$D_i, g_i(d)$	Durée de séjour et probabilité d'une durée d	pas ; sans unité
$\mathbf{c}_t$	Vecteur de contexte : charge, ambiance, régime	selon composantes
$\mathcal{T}$	Paramètre de calibration des logits	sans unité
$\theta, \mathcal{L}$	Paramètres appris et fonction de coût	selon modèle ; sans unité
TP, FP, FN, TN	Vrais positifs, faux positifs, faux négatifs, vrais négatifs	effectifs

Conventions de lecture. Une durée exprimée en trames ne devient une durée en secondes qu'après identification de la cadence. Une aire en pixels ne devient une surface physique qu'après calibration géométrique. Le paramètre $\mathcal{T}$ de calibration probabiliste ne désigne pas la température du moteur. Les symboles de masque M ou G sont définis localement et ne doivent pas être confondus avec l'exitance radiative.

Table des matières

Avant-propos i

Dédicaces ii

Remerciements iii

Résumé iv

Abstract v

Liste des abréviations, sigles et acronymes vi

Liste des symboles et des unités viii

Table des figures xiv

Table des tableaux xv

Introduction générale 1

I Présentation de l'entreprise d'accueil 3

1 Présentation de l'entreprise d'accueil 4
- 1.1 Identité et positionnement . . . 4
- 1.2 Approche et valeurs . . . 5
- 1.3 Métiers et services . . . 5
- 1.4 Produits, solutions et domaines d'intervention . . . 5
- 1.5 Recherche, développement et lien avec le stage . . . 6

II Fondements thermographiques et Analyse Concurrentielle Industrielle 7

2 Thermographie infrarouge et chaîne de mesure 8
- 2.1 Température, chaleur et rayonnement . . . 8
- 2.2 Formation d'un thermogramme . . . 9
- 2.3 Caméra FLIR C5 : spécifications vérifiées . . . 9
- 2.4 Résolution spatiale et limites . . . 10

3 Analyse concurrentielle et positionnement industriel 11
3.1 Panorama des technologies de surveillance de l'état de santé 11
3.2 Benchmarking des solutions commerciales et industrielles 12
3.2.1 Écosystème industriel, acteurs dominants et cas d'usage 13
3.2.2 Déploiements industriels et maturité opérationnelle 14
3.3 Positionnement scientifique et valeur ajoutée du projet 14

III Jeu de données, Environnement Technologique et Paramètres d'entraînement 15

4 Jeux de données et préparation des images 16
4.1 Deux ensembles pour des tâches distinctes 16
4.2 Classification : définition des six classes 16
4.3 Localisation et séquences : ensemble BNUT 17
4.4 Nettoyage et conservation de l'information 18
4.5 Préparation des données et augmentation conforme à la physique 19
4.5.1 Élimination du biais de raccourci (Shortcut Bias) 19
4.5.2 Augmentation de données guidée par les contraintes thermodynamiques 19

5 Cadre expérimental, reproductibilité et paramétrage des modèles 21
5.1 Plateformes d'exécution et environnement matériel 21
5.2 Socle logiciel, bibliothèques et versions certifiées 22
5.3 Description détaillée des hyperparamètres et architectures 22
5.3.1 Axe 1 : Modèles graphiques probabilistes et markoviens 22
5.3.2 Axe 2 : Réseaux de neurones convolutifs (CNN et Attention U-Net) 23

IV Comparaison des méthodes de classification 25

6 Classification directe par réseaux convolutifs 26
6.1 Principe d'un CNN 26
6.2 CNN personnalisé 27
6.3 Transfert d'apprentissage 27
6.4 Architectures comparées 28

7 Approche hybride CNN et Machine Learning 29
7.1 Architecture générale 29
7.2 Classifieurs évalués 29
7.2.1 Support Vector Machine 29
7.2.2 Random Forest 30
7.2.3 XGBoost 30
7.2.4 K plus proches voisins 30
7.2.5 Régression logistique 31
7.3 Métriques 32

8 Résultats expérimentaux consolidés 33
8.1 CNN directs . . . 33
8.2 Modèles hybrides . . . 34
8.3 Comparaison finale . . . 34
8.4 Enseignements . . . 35

V Localisation, suivi temporel et aide à la maintenance 38

9 Architecture du diagnostic spatio-temporel 39
9.1 De la classe d'image à l'état suivi . . . 39
9.2 Interfaces entre les traitements . . . 39
9.3 Continuité de l'interprétation . . . 40
9.4 Modèles stochastiques : Comprendre les concepts de MRF, HMM et HSMM 41
9.4.1 Le Champ Aléatoire de Markov (MRF) : La cohérence spatiale dans l'image . . . 41
9.4.2 Le Modèle de Markov Caché (HMM) : La trajectoire temporelle de santé . . . 42
9.4.3 Le Modèle Semi-Markovien Caché (HSMM) : La prise en compte du temps de séjour . . . 43

10 Prétraitement spatial et construction des observations 44
10.1 Descripteurs physiques interprétables . . . 44
10.2 Indicateur synthétique de santé . . . 44

11 Modélisation probabiliste et anticipation du risque 45
11.1 Probabilité et mise à jour d'une hypothèse . . . 45
11.2 MRF : cohérence entre pixels voisins . . . 45
11.3 Optimisation par ICM . . . 46
11.4 HMM : actualiser la santé à partir de l'historique . . . 46
11.5 Chaîne absorbante et matrice fondamentale . . . 47
11.6 Exemple numérique contrôlable à la main . . . 47
11.7 Risque à horizon fini et durée de vie restante . . . 48

12 Segmentation profonde, contexte et durée 49
12.1 U-Net : apprendre une carte spatiale . . . 49
12.2 Annotations, fonction de coût et interprétation . . . 50
12.3 CNN contextuel : connaître le régime de fonctionnement . . . 50
12.4 Calibration des probabilités . . . 50
12.5 Incertitude par Monte Carlo dropout . . . 51
12.6 HSMM : rendre la durée explicite . . . 52
12.7 Fusion et alerte explicable . . . 52

13 Résultats spatio-temporels et discussion 53
13.1 Cadre de la comparaison . . . 53
13.2 Qualité de la localisation . . . 53

13.3 Détection contextuelle 54
13.4 Suivi, stabilité et délai 54
13.5 Portée et conditions de généralisation 55

14 Exploitation et aide à la décision 56
14.1 Lecture conjointe des observations 56
14.2 Causalité et continuité du suivi 56
14.3 Décision et rôle de l'opérateur 57
14.4 Perspective d'intégration IoT 57
14.5 Accès au projet 58
14.6 Perspectives 58

VI Étude comparative : Modèles de Markov versus Réseaux Convolutifs 59

15 Étude comparative : Modèles de Markov versus Réseaux Convolutifs 60
15.1 Fondements conceptuels et divergence épistémologique 60
15.2 Confrontation quantitative sur banc d'évaluation expérimental 61
15.3 Analyse croisée des forces, limites et domaines d'adéquation 62
15.3.1 Modèles de Markov : explicabilité, réactivité et sobriété calculatoire 62
15.3.2 Réseaux convolutifs : précision spatiale et discrimination sous charges variables 62
15.4 Complémentarité opérationnelle et architecture hybride conjointe 63

Conclusion générale et perspectives 64

Bibliographie 66

Webographie 68

A Compléments mathématiques 70
A.1 Probabilité d'absorption à horizon fini 70
A.2 Récurrence de fin de segment d'un HSMM 70
A.3 Équation thermique de référence 71

B Annexes expérimentales : lecture d'une projection 72

Glossaire 73

Index alphabétique 75

Table des figures

1.1 Logo de Smart Automation Technologies. 4
1.2 Valeurs de Smart Automation Technologies. 5

2.1 Position de l'infrarouge dans le spectre électromagnétique. Source : Gisrsstudy [38]. 8
2.2 Exemple d'usage d'une caméra thermique pour l'inspection d'un moteur. Source : inspecter-un-moteur-avec-une-camera-thermique [35]. 9

3.1 Dynamique du marché mondial de la maintenance prédictive, répartition des acteurs technologiques dominants et axes de déploiement (Source : *IoT Analytics Research* [36]). 13

4.1 Exemples des six classes de fonctionnement. Images : jeu *Induction Motor–Thermal Images* [22]. 17
4.2 Signatures thermiques de plusieurs conditions de fonctionnement 18
4.3 Images originales et images nettoyées. Images de base : *Induction Motor–Thermal Images* [22] ; comparaison du prétraitement de l'étude. 18

6.1 Chaîne conceptuelle d'un réseau convolutif, de l'image aux probabilités. Source : Dragon1 [39]. 26
6.2 Réduction par max-pooling (à gauche) et transformation Softmax des sorties (à droite). Source : deeplizard [40]. 27
6.3 Principe du dropout : désactivation aléatoire d'une fraction des neurones pendant l'entraînement. Source : Towards Data Science [41]. 28

7.1 Pipeline hybride : prétraitement, extraction CNN, stockage des caractéristiques et classification. Source : inspirée d'une architecture hybride CNN–Random Forest [42]. 29
7.2 Représentations pédagogiques du SVM et du Random Forest. Sources : scikit-learn [30] et MLU-Explain [43]. 30
7.3 Représentations pédagogiques de XGBoost et de KNN. Sources : documentation XGBoost [31] et IBM [32]. 31
7.4 Fonction sigmoïde utilisée par la régression logistique binaire. 31
7.5 Lecture pédagogique d'une matrice de confusion binaire. 32

8.1 Comparaison des cinq CNN directs. 33
8.2 MobileNetV2 : courbes d'apprentissage et matrice de confusion. 34
8.3 DenseNet121 direct : courbes d'apprentissage et matrice de confusion. . . . 34

8.4 Concentration des prédictions de ResNet50 et EfficientNetB0 sur la classe HFL dans cette expérience. 35
8.5 Classement des dix meilleurs modèles hybrides. 36
8.6 Matrices de confusion des deux meilleurs modèles hybrides. 36
8.7 Classement final des quinze meilleurs modèles directs et hybrides. 37

9.1 Architecture fonctionnelle cible : deux axes complémentaires et une évaluation commune. Schéma de synthèse du projet. 40
9.2 Représentation en grille d'un champ de Markov spatial (MRF). Les sites blancs représentent les étiquettes de segmentation latentes couplées à leur voisinage spatial, et les nœuds foncés représentent les pixels thermiques observés (Source : [44]). 41
9.3 Chaîne de Markov Cachée temporelle (HMM). L'évolution de l'état de santé latent S_t pilote stochastiquement les observations physiques continues $\mathbf{o}_t$ (Source : [45]). 42
9.4 Modèle Semi-Markovien Caché (HSMM). Chaque macro-état S_i est explicitement associé à une loi de distribution de durée de séjour d_i régissant le nombre d'observations émises avant toute transition d'état (Source : [46]). 43

11.1 Voisinage spatial d'un pixel. Schéma pédagogique original. 45
11.2 Segmentation par MRF et optimisation ICM 46
11.3 Risque selon l'horizon et l'état initial 48

12.1 Principe encodeur–décodeur simplifié à deux niveaux, redessiné d'après U-Net [19]. 49
12.2 Annotations et prédictions U-Net. Images et annotations : jeu BNUT [23]. La concordance est interprétée selon la nature de la cible. 51

14.1 Trajectoires thermiques et états suivis 56
14.2 Enchaînement des informations nécessaires à une décision assistée. 57
14.3 Interface de l'application de diagnostic. 58

B.1 Projection du risque depuis un état courant 72

Liste des tableaux

2.1 Caractéristiques principales de la FLIR C5 10

3.1 Matrice d'évaluation concurrentielle des solutions de surveillance pour machines tournantes. 12

4.1 Rôle des jeux de données dans le mémoire 16
4.2 Définition des classes et répartition de la partition de classification 16

5.1 Spécification des frameworks, bibliothèques et rôles opérationnels. 22

6.1 Profil des cinq architectures directes 28

7.1 Comparaison pratique des classifieurs hybrides 32

8.1 Performances des CNN directs sur les 100 images de validation 33
8.2 Dix meilleures combinaisons hybrides 35

9.1 Informations transmises entre les principales étapes 39

13.1 Mesures de segmentation enregistrées dans la synthèse expérimentale [47] . 53
13.2 Détection contextuelle : mesures enregistrées [47] 54
13.3 Mesures temporelles enregistrées [47] 54

15.1 Synthèse comparative des performances métrologiques, temporelles et opérationnelles. 61

Introduction générale

Contexte industriel

Les moteurs asynchrones assurent de nombreux entraînements industriels. Une dégradation de roulement, un défaut d'alignement, une surcharge ou une ventilation insuffisante peuvent modifier les pertes et la répartition de température à la surface de la machine. La **maintenance conditionnelle** cherche à repérer ces changements pour éclairer la décision d'intervention ; la **maintenance prévisionnelle** ajoute une dimension d'anticipation.

La thermographie infrarouge offre une observation sans contact, compatible avec un équipement en fonctionnement. Son utilisation pour la surveillance des machines suppose toutefois un protocole de mesure maîtrisé [21]. L'image dépend de la surface, de l'environnement et des réglages de la caméra. Son interprétation ne peut donc pas reposer sur la seule présence d'une couleur chaude.

Les méthodes d'apprentissage profond permettent d'extraire des représentations visuelles adaptées à la classification et à la segmentation. Des travaux sur le diagnostic de moteurs explorent notamment les réseaux convolutifs et leur association à des méthodes d'apprentissage classiques [10, 11, 12]. Le présent travail compare les **modèles de Markov** et les **réseaux convolutifs** pour la détection automatique des défauts industriels, en prenant les moteurs asynchrones et leurs signatures thermiques comme cas d'étude.

Problématique

Question directrice. Quels sont les apports et les limites respectifs des modèles de Markov et des CNN pour détecter les défauts industriels, et comment les intégrer à une chaîne de surveillance connectée ?

Cette problématique implique de distinguer trois tâches. La **classification** reconnaît un état dans une image. La **segmentation** localise la région dont les caractéristiques sont utiles. Le **suivi temporel** examine la persistance et les transitions entre états. Ces tâches sont complémentaires, mais leurs résultats et leurs métriques ne sont pas interchangeables.

Objectifs et périmètre

L'étude poursuit quatre objectifs : établir les conditions d'une interprétation thermique fiable, comparer les approches markoviennes et convolutives sur des tâches définies, relier les observations spatiales à des états de santé et formuler une anticipation probabiliste explicable.

La dimension **Internet des objets (IoT)** correspond ici à la perspective d'une acquisition connectée et d'une transmission des observations vers le traitement et la supervision. Les expériences présentées reposent sur des jeux de données et des résultats logiciels ; elles ne constituent pas une validation de bout en bout d'un déploiement IoT sur une installation industrielle. La section 14.4 précise cette perspective d'intégration.

La classification est étudiée sur 488 images réparties entre six combinaisons de santé du roulement et de charge. La localisation et le suivi mobilisent un second ensemble de thermogrammes et d'annotations. Les caractéristiques de ces deux jeux sont présentées ensemble au chapitre 4, afin de clarifier leurs rôles respectifs.

La comparaison porte sur cinq réseaux convolutifs directs, vingt associations entre extracteurs et classifieurs, puis deux chaînes spatio-temporelles. Le risque considéré est une **probabilité de premier passage** vers un état critique. Il ne doit pas être confondu avec une prédiction exacte de la durée de vie restante.

Démarche et statut des résultats

Les performances sont analysées avec leur protocole, leurs cibles et leurs limites. Une mesure sur une partition interne ne démontre pas une robustesse à une autre machine, une autre caméra ou une autre session d'acquisition. Les exemples numériques servent à expliciter les méthodes ; ils sont distingués des mesures expérimentales.

Principe de lecture. Le mémoire distingue la formulation théorique d'une méthode, son implémentation et les résultats enregistrés. La disponibilité d'un code ou d'un tableau ne vaut pas à elle seule validation indépendante de toutes les affirmations associées.

Organisation du mémoire

Après les pages liminaires, l'ouvrage s'articule en six parties complémentaires. La première introduit l'entreprise SAT, suivie des fondements thermiques et de l'analyse concurrentielle en deuxième partie. La troisième détaille les données, l'environnement logiciel et le paramétrage des modèles. La quatrième et la cinquième évaluent respectivement la classification CNN et la modélisation spatio-temporelle (MRF, HMM, pronostic absorbant). La sixième partie confronte formellement les paradigmes markovien et convolutif avant d'aboutir à leur synergie hybride. La conclusion générale synthétise les apports, complétée par la bibliographie, les annexes, le glossaire et l'index.

Première partie

Présentation de l'entreprise d'accueil

Chapitre 1

Présentation de l'entreprise d'accueil

1.1 Identité et positionnement

Smart Automation Technologies (SAT) est une entreprise spécialisée dans l'ingénierie des technologies de l'information et l'intelligence artificielle. Son document institutionnel indique une création en **mai 2021** sous le statut de **société à responsabilité limitée (SARL)**.

Elle a été fondée par un groupe de consultants seniors, de jeunes docteurs et d'ingénieurs spécialisés dans les technologies de l'information, la science des données et l'intelligence artificielle .

Smart Automation Technologies fait de l'innovation. Son crédo est investi en recherche et développement afin d'être à la pointe du progrès dans la technologie de l'information et l'intelligence artificielle.

SAT accompagne les entreprises et les administrations dans la conception, la mise en œuvre et l'évolution de leurs systèmes d'information. Son intervention couvre les études, la formation, le développement informatique, les progiciels intégrés et les services IT. L'entreprise présente son rôle comme celui d'un partenaire durable : apporter les compétences techniques nécessaires afin que ses clients puissent se concentrer sur leur cœur de métier.

La recherche et développement occupe une place importante dans ce positionnement. L'innovation est envisagée comme un moyen d'adapter les solutions aux besoins, aux contraintes et aux transformations des organisations accompagnées.

Figure 1.1 : Logo de Smart Automation Technologies.

1.2 Approche et valeurs

L'approche de SAT met l'accent sur l'éthique, la déontologie, la transparence et l'engagement. La proximité avec les clients vise à construire une relation de confiance et une compréhension partagée des besoins. L'entreprise souligne également l'importance du capital humain, à travers l'encadrement, le suivi, l'évaluation et la formation continue de ses collaborateurs .

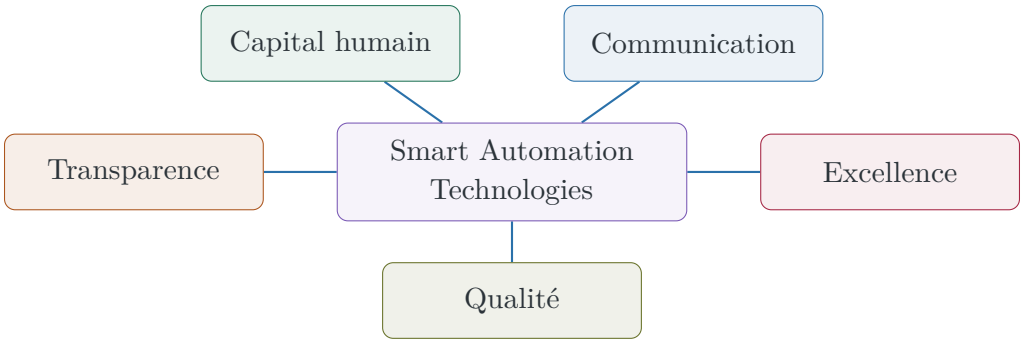

Figure 1.2 : Valeurs de Smart Automation Technologies.

1.3 Métiers et services

Les prestations de SAT s'organisent autour de quatre domaines complémentaires .

Étude et conseil
Accompagnement de la prise de décision, de la prévention des risques et des réflexions stratégiques liées à la transformation des organisations. Le conseil vise à éclairer une situation et à construire une réponse adaptée aux changements envisagés.

Audit
Analyse des besoins et des solutions afin d'améliorer leur qualité et leur adéquation aux objectifs de l'organisation, dans une perspective durable.

Conduite et accompagnement du changement
Traduction de la stratégie de l'entreprise en orientations pour un système d'information intelligent et décisionnel, depuis la réflexion stratégique jusqu'à la mise en place opérationnelle.

Intégration et développement
Conception d'applications spécifiques et intégration de solutions adaptées aux besoins métiers, avec une attention portée à l'efficacité, à la pertinence et à l'expertise technique.

1.4 Produits, solutions et domaines d'intervention

L'offre de SAT associe services, solutions dédiées, support et formation. Sa démarche de conseil articule les dimensions **client**, **projet** et **méthode**. Elle comprend notamment la gouvernance IT et le management de projets, la conduite du changement, l'élaboration de schémas directeurs informatiques, l'urbanisation des systèmes d'information, l'assistance à

maîtrise d'ouvrage et l'architecture logicielle. Elle couvre aussi les solutions clés en main, l'analyse comparative et l'audit logiciel, ainsi que l'automatisation du marketing .

Les domaines d'application cités sont l'industrie, la logistique, le marketing et la finance. SAT présente également le concept **EcoDID**, pour *écosystème digital, intelligent et décisionnel*, comme un cadre de transformation numérique des organisations.

1.5 Recherche, développement et lien avec le stage

Le SAT propose plusieurs axes de recherche et développement en partenariat avec les milieux universitaire et industriel :

— Une technologie *Edge Box* dédiée à la maintenance prédictive ;
— Une technologie *Edge data center* ;
— Une plateforme logistique *Smart DLSP* fondée sur EcoDID ;
— Des plateformes marketing et éducative reposant sur le même concept.

Ces éléments décrivent les orientations exposées par l'entreprise et ne préjugent pas du niveau de déploiement effectif de chaque solution.

Le stage relie ainsi **intelligence artificielle**, **diagnostic industriel** et **surveillance connectée**. La comparaison Markov–CNN est appliquée à la thermographie de moteurs asynchrones, avec une perspective d'intégration IoT.

Deuxième partie

Fondements thermographiques et Analyse Concurrentielle Industrielle

Chapitre 2

Thermographie infrarouge et chaîne de mesure

2.1 Température, chaleur et rayonnement

La **température** caractérise l'état thermique d'un système ; la **chaleur** est une énergie transférée du fait d'une différence de température. Les trois modes de transfert sont la conduction, la convection et le rayonnement. Une caméra thermique ne voit donc pas directement la chaleur interne : elle mesure un flux radiatif provenant de la surface et en déduit une température apparente.

Pour une surface grise idéale, l'exitance totale s'écrit selon Stefan–Boltzmann :

$$M = \varepsilon \sigma_{\mathrm{SB}} T^4, \tag{2.1}$$

où ε est l'émissivité, $\sigma_{\mathrm{SB}} \simeq 5{,}670 \times 10^{-8}\,\mathrm{W\,m^{-2}\,K^{-4}}$ et T la température absolue. La distribution spectrale est décrite par la loi de Planck [4] :

$$L_\lambda(T) = \frac{2 h_{\mathrm{P}} c^2}{\lambda^5} \frac{1}{\exp\!\left(\frac{h_{\mathrm{P}} c}{\lambda k_{\mathrm{B}} T}\right) - 1}. \tag{2.2}$$

L'énergie d'un photon vérifie $E = h_{\mathrm{P}}\nu = h_{\mathrm{P}} c/\lambda$. Aux températures industrielles usuelles, une part utile du rayonnement se trouve dans l'infrarouge à grandes longueurs d'onde.

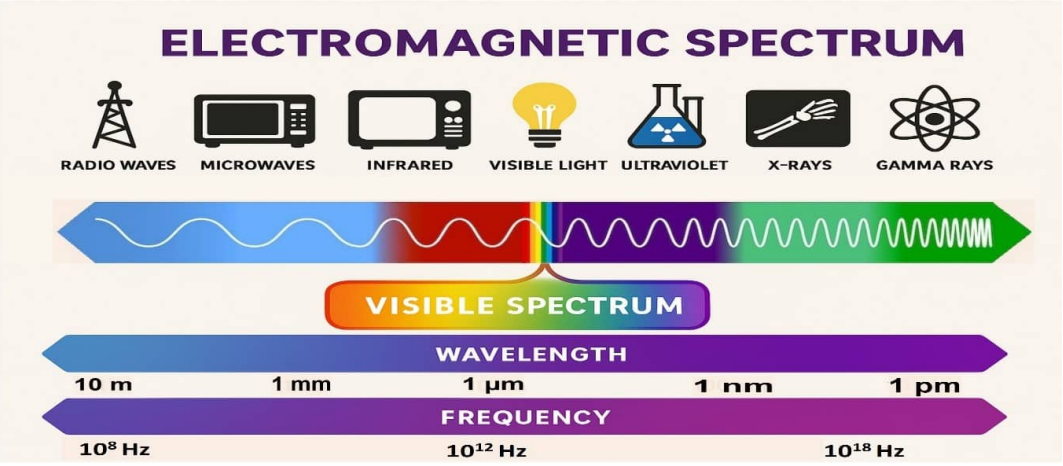

Figure 2.1 : Position de l'infrarouge dans le spectre électromagnétique. Source : Gisrsstudy [38].

2.2 Formation d'un thermogramme

Le microbolomètre convertit le rayonnement incident en variation électrique. La caméra applique ensuite une calibration, une palette et, selon le mode, une fusion avec l'image visible. La couleur affichée code une valeur selon une palette ; elle n'est pas une propriété physique de la surface. L'image exportée ne conserve pas nécessairement les données nécessaires à une conversion en température.

Figure 2.2 : Exemple d'usage d'une caméra thermique pour l'inspection d'un moteur. Source : inspecter-un-moteur-avec-une-camera-thermique [35].

Les grandeurs influentes sont l'émissivité de la surface, la température apparente réfléchie, la distance, l'humidité, la température ambiante, l'angle d'observation et la mise au point. Les surfaces métalliques polies, très réfléchissantes, peuvent renvoyer l'image thermique de l'opérateur ou d'une source chaude. Une comparaison fiable exige donc une géométrie répétable et des paramètres documentés.

2.3 Caméra FLIR C5 : spécifications vérifiées

La FLIR C5 est une caméra thermique compacte destinée aux activités d'inspection et de maintenance. Sa plage de mesure s'étend de -20 à $400\,^{\circ}\mathrm{C}$, son champ de vision est de $54^{\circ} \times 42^{\circ}$, sa sensibilité thermique est inférieure à 70 mK et sa masse est d'environ 0,19 kg [24]. Le tableau 2.1 synthétise ses principales caractéristiques.

Table 2.1 : Caractéristiques principales de la FLIR C5

Paramètre	Valeur vérifiée
Résolution infrarouge	160×120 pixels, soit 19 200 mesures
Bande spectrale	8 à 14 μm
Plage de mesure	-20 à 400 °C
Sensibilité thermique	NETD < 70 mK
Champ de vision	$54° \times 42°$
Résolution spatiale	6,3 mrad/pixel
Fréquence d'image	8,7 Hz
Caméra visible	5 mégapixels
Modes	thermique, visible, MSX et incrustation
Protection	IP54 ; résistance à une chute de 2 m annoncée
Masse	environ 0,19 kg, batterie incluse

2.4 Résolution spatiale et limites

À une distance d, la taille approximative couverte par un pixel est $s \simeq d \times \mathrm{IFOV}$. Avec 6,3 mrad/pixel, un pixel couvre environ 6,3 mm à 1 m. Une mesure robuste exige généralement plusieurs pixels sur la cible ; les petits défauts ne sont donc pas résolus à grande distance.

Les principales limites sont :

- mesure de surface seulement ;
- résolution thermique et spatiale modestes ;
- erreurs possibles sur métal brillant ou émissivité inconnue ;
- dépendance aux conditions ambiantes et à la charge du moteur ;
- palettes et ajustements automatiques susceptibles de modifier l'apparence sans modifier la physique ;
- nécessité d'une calibration et d'un protocole de référence.

Ces contraintes justifient une approche combinant classification d'image, métadonnées d'acquisition et, à terme, suivi temporel de la température.

Mesure et représentation. Dans la suite du mémoire, les grandeurs sont exprimées en température seulement si la calibration le permet. Sinon, les expressions « intensité normalisée » et « contraste relatif » sont utilisées. Un thermogramme observe la surface : il ne mesure pas directement la température interne d'un roulement.

Chapitre 3

Analyse concurrentielle et positionnement industriel

La surveillance conditionnelle des machines tournantes constitue un enjeu économique majeur pour les industries manufacturières et de transformation. L'apparition d'un défaut mécanique ou électrique non détecté sur un moteur asynchrone entraîne des arrêts de ligne imprévus dont le coût horaire peut atteindre plusieurs dizaines de milliers d'euros. Si diverses technologies de diagnostic coexistent sur le marché, l'émergence de la thermographie infrarouge automatisée modifie profondément la gestion des parcs d'équipements.

3.1 Panorama des technologies de surveillance de l'état de santé

Historiquement, le diagnostic des moteurs électriques repose sur trois grandes familles de mesure non destructives :

1. **L'analyse vibratoire :** Considérée comme la référence mécanique, elle mesure les accélérations périodiques au niveau des paliers. Elle excelle dans l'identification précise des chocs sur les bagues de roulements à un stade avancé. Néanmoins, elle requiert la fixation directe de capteurs piézoélectriques sur la carcasse de chaque machine, ce qui engendre des coûts d'instrumentation et de câblage élevés pour des parcs étendus.
2. **L'analyse des signatures de courant statorique (MCSA) :** Elle surveille les harmoniques de courant induites par des asymétries de flux magnétique, typiques des ruptures de barres rotoriques ou de courts-circuits entre spires. Bien que non intrusive mécaniquement car mesurée au niveau du tableau général basse tension (TGBT), la MCSA souffre d'un manque de sensibilité aux défauts mécaniques naissants sous charge variable ou faible.
3. **La thermographie infrarouge (TIR) :** Elle capte le flux radiatif émis par les surfaces de la machine. Tout frottement anormal, défaut d'alignement ou échauffement d'enroulement se traduit par une dissipation thermique localisée. Son atout fondamental réside dans sa nature surfacique, bidimensionnelle et totalement sans contact mécanique.

3.2 Benchmarking des solutions commerciales et industrielles

Le marché de la surveillance thermique industrielle se divise actuellement en trois catégories de solutions, récapitulées dans le tableau 3.1.

Table 3.1 : Matrice d'évaluation concurrentielle des solutions de surveillance pour machines tournantes.

Famille de solution	Mécanisme de diagnostic	Avantages opérationnels	Limites majeures
Caméras portables de maintenance *(ex. Fluke Ti480, FLIR T-Series)*	Inspection manuelle périodique par thermographe qualifié. Seuillage statique de température (ΔT critique).	Précision métrologique élevée, étalonnage d'usine certifié, portabilité.	Surveillance discontinue, temps de main-d'œuvre important, dérives lentes non captées entre deux rondes.
Systèmes vibratoires connectés *(ex. SKF Enlight, Schaeffler OPTIME)*	Capteurs sans fil mesurant accélération et température de contact sur roulement.	Automatisation du relevé, alertes configurables, intégration GMAO native.	Mesure thermique ponctuelle non spatialisée, dépendance géométrique stricte au point de contact.
Plateformes logicielles IoT généralistes *(ex. Schneider EcoStruxure)*	Agrégation de variables scalaires (courant, puissance, température ambiante) avec IA tabulaire.	Supervision globale de l'installation, tableaux de bord de tendance clairs.	Absence d'analyse de morphologie thermique, sensibilité aux faux positifs sous variation de régime.
Approche développée *(Smart Automation Technologies)*	Flux matriciel thermique continu couplé à une analyse conjointe Markov / CNN.	Localisation automatique des zones critiques, détection précoce des gradients, explicabilité formelle du risque.	Nécessite une ligne de visée optique dégagée et la maîtrise de l'émissivité surfacique.

3.2.1 Écosystème industriel, acteurs dominants et cas d'usage

Le marché de la maintenance prévisionnelle (PdM) connaît une phase d'expansion accélérée sous l'effet de la convergence entre l'Internet des objets industriel (IIoT) et l'apprentissage automatique. D'après les analyses sectorielles publiées par le cabinet de recherche *IoT Analytics* [36], la valorisation globale du marché de la maintenance prédictive est passée de 5,48 milliards de dollars en 2022 à plus de 14,2 milliards de dollars projetés à l'horizon 2028, affichant un taux de croissance annuel composé (TCAC) soutenu de 17 % (Figure 3.1).

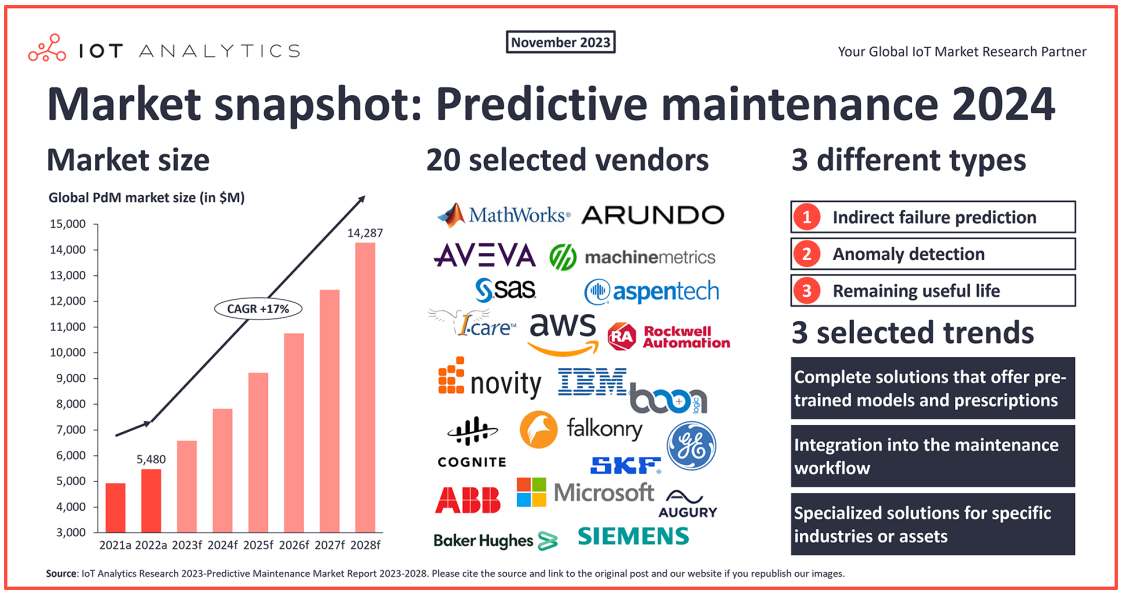

Figure 3.1 : Dynamique du marché mondial de la maintenance prédictive, répartition des acteurs technologiques dominants et axes de déploiement (Source : *IoT Analytics Research* [36]).

Comme l'illustre la cartographie concurrentielle, l'écosystème se structure autour de plusieurs groupes d'entreprises aux profils technologiques distincts :

— **Les équipementiers électromécaniques et constructeurs de machines :** Les leaders mondiaux tels que **Siemens** (avec la suite *Senseye Predictive Maintenance*), **ABB** (plateforme *ABB Ability*), et **SKF** (gamme de capteurs *Enlight* et services de diagnostic de roulements) dominent le terrain grâce à leur proximité directe avec la machine et leur connaissance fine des lois de comportement mécanique.

— **Les géants de l'automatisation industrielle et de l'énergie :** Des groupes comme **Schneider Electric** (suite logicielle *EcoStruxure Asset Advisor*), **Rockwell Automation** et **Baker Hughes** orientent leur offre vers la gestion intégrée des actifs et la supervision d'usines complètes.

— **Les fournisseurs d'infrastructures Cloud et Big Data : Amazon Web Services** (avec le service managé *AWS IoT SiteWise* et *Amazon Lookout for Equipment*) et **Microsoft Azure** fournissent l'infrastructure de traitement distribué et les pipelines d'apprentissage automatique à grande échelle, en partenariat direct avec les intégrateurs industriels.

3.2.2 Déploiements industriels et maturité opérationnelle

L'adoption de ces solutions s'articule aujourd'hui autour de trois cas d'usage majeurs en production :

1. **La détection d'anomalies en temps réel :** Déployée massivement dans l'industrie automobile (ex. usines de carrosserie et d'emboutissage chez Stellantis et Renault) pour détecter immédiatement tout échauffement anormal ou grippage mécanique sur les lignes robotisées.
2. **La surveillance des machines critiques en continu :** Utilisée dans les secteurs de la production d'énergie, de la pétrochimie et du traitement de l'eau (notamment sur les groupes motopompes et compresseurs), où l'arrêt imprévu d'un moteur asynchrone principal entraîne l'arrêt complet du procédé continu.
3. **L'estimation de la durée de vie résiduelle (RUL) :** Cible prioritaire des secteurs ferroviaire et aéronautique, permettant d'anticiper le remplacement d'un roulement lors d'un arrêt technique programmé plutôt qu'en urgence.

C'est précisément sur ce troisième volet que la présente étude apporte sa plus-value, en comblant le fossé entre la haute fidélité spatiale des représentations d'images thermiques et la modélisation formelle du risque de défaillance à horizon fini.

3.3 Positionnement scientifique et valeur ajoutée du projet

Face à ces approches, le travail conduit au sein de Smart Automation Technologies (SAT) se distingue par l'exploitation complète du champ d'observation thermique bidimensionnel couplé à une dynamique temporelle. Plutôt que d'imposer un seuil thermique statique d'échauffement maximal (souvent déclenché trop tardivement lors de surchauffes avérées), la méthodologie combine :

— Une discrétisation fine de la signature spatiale pour isoler la composante défectueuse (palier avant, flasque, carter à ailettes) ;
— Un suivi probabiliste continu capable d'identifier un changement d'état thermodynamique bien avant le dépassement d'un seuil critique ;
— Une chaîne de décision transparente fournissant à l'opérateur non seulement une classe de fonctionnement, mais également une estimation du temps résiduel avant dégradation critique.

Troisième partie

Jeu de données, Environnement Technologique et Paramètres d'entraînement

Chapitre 4

Jeux de données et préparation des images

4.1 Deux ensembles pour des tâches distinctes

La classification selon la santé du roulement et la charge s'appuie sur *Induction Motor–Thermal Images*, publié sur Mendeley Data. La localisation et l'étude séquentielle utilisent le jeu de thermogrammes BNUT et ses annotations spatiales [22, 23]. Les deux ensembles sont complémentaires ; ils ne constituent pas une acquisition unique et ne doivent pas être fusionnés sans prise en compte du domaine d'origine.

Table 4.1 : Rôle des jeux de données dans le mémoire

Ensemble	Composition	Utilisation
FLIR	488 images ; six classes de roulement et de charge	Classification directe et hybride
BNUT	369 thermogrammes dans l'organisation étudiée ; onze conditions et quarante masques	Segmentation et analyse des séquences

4.2 Classification : définition des six classes

Les sigles combinent l'état du roulement, sain ou corrodé, et le niveau de charge, nul, moyen ou plein. La version 2 du jeu FLIR a été publiée le 2 mars 2026 sous licence CC BY 4.0 [22]. L'article associé étudie la maintenance prédictive par images thermiques et apprentissage profond [3].

Table 4.2 : Définition des classes et répartition de la partition de classification

Classe	Signification	Total	Entraîn.	Valid.
CFL	Roulement corrodé à pleine charge	49	39	10
CML	Roulement corrodé à charge moyenne	79	63	16
CNL	Roulement corrodé à vide	76	60	16
HFL	Roulement sain à pleine charge	112	89	23
HML	Roulement sain à charge moyenne	82	65	17
HNL	Roulement sain à vide	90	72	18
Total		488	388	100

La classe HFL contient plus du double d'images de CFL. Le **déséquilibre des classes** reste modéré, mais il justifie l'examen des moyennes macro en complément de l'exactitude globale. Les 388 images correspondent à l'entraînement, et non à la totalité du jeu.

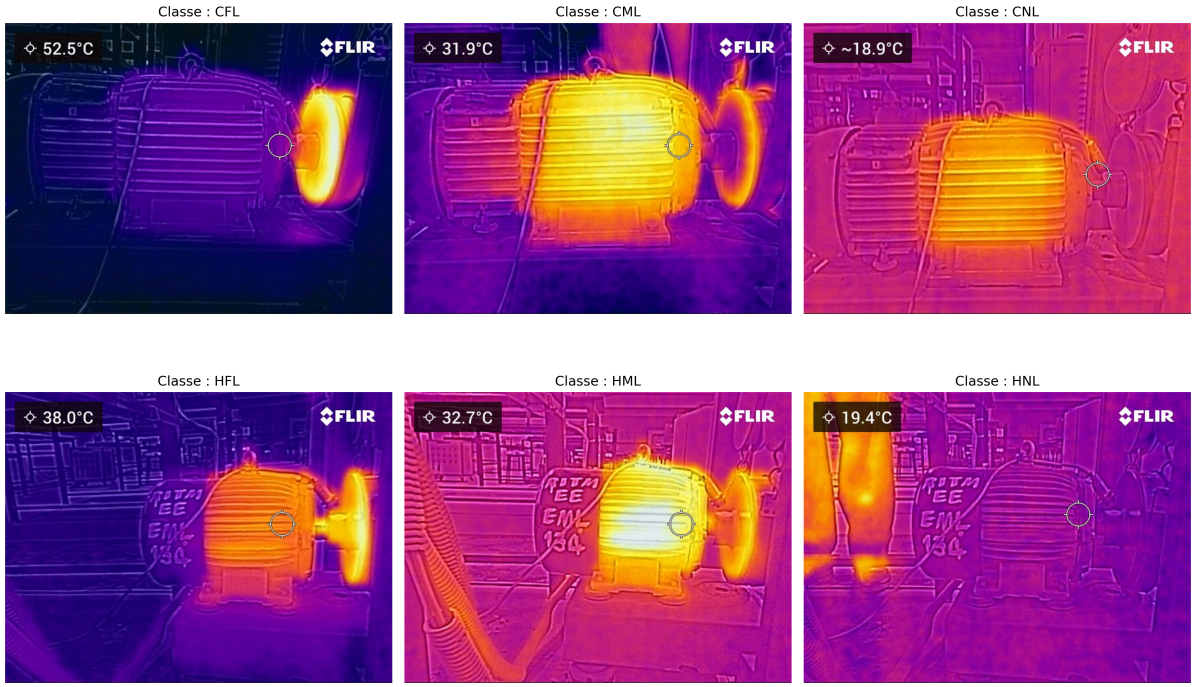

Figure 4.1 : Exemples des six classes de fonctionnement. Images : jeu *Induction Motor–Thermal Images* [22].

4.3 Localisation et séquences : ensemble BNUT

Le jeu BNUT couvre un fonctionnement nominal, des défauts statoriques, une défaillance de ventilation et un blocage de rotor. La description du dépôt précise une acquisition avec une caméra Dali-tech T4/T8, une ambiance de 23 °C et l'ajout de quarante annotations en version 3 [23]. Les identifiants de séquence distinguent notamment `Noload`, les essais statoriques `A10`, `A30` et `A50`, ainsi que `Fan` et `Rotor-0`.

Ces conditions ne correspondent pas directement aux six classes FLIR. Un état latent « suspect » du suivi probabiliste ne doit pas non plus être assimilé automatiquement à une étiquette de roulement corrodé. Chaque tâche conserve sa propre définition de cible.

Sens des annotations spatiales. Un masque peut désigner la silhouette de la machine, une région chaude ou une zone diagnostiquée défaillante. La consigne d'annotation conditionne la signification du Dice et de l'IoU. Cette distinction sera reprise uniquement lors de l'interprétation des résultats de segmentation.

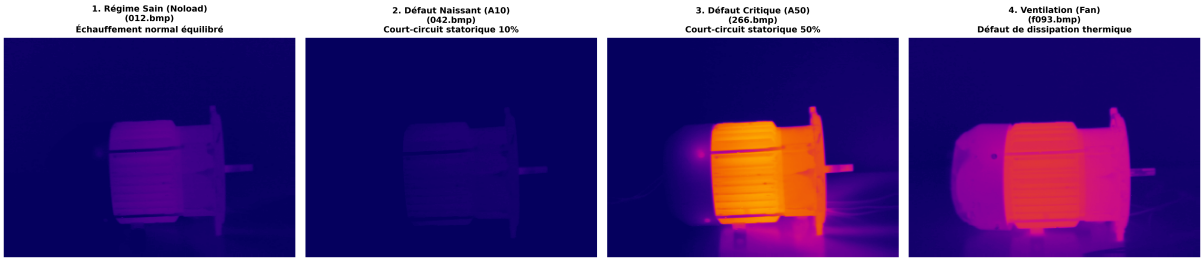

Figure 4.2 : Signatures thermiques de plusieurs conditions de fonctionnement. Thermogrammes BNUT [23]. L'intensité, la dissymétrie et l'extension de la région observée sont interprétées avec le contexte d'essai.

4.4 Nettoyage et conservation de l'information

Les thermogrammes FLIR comportent des surimpressions : température, viseur, logo et annotations. Le prétraitement masque une partie de ces éléments. Il réduit les indices textuels directement accessibles au classifieur, mais peut créer des contours artificiels.

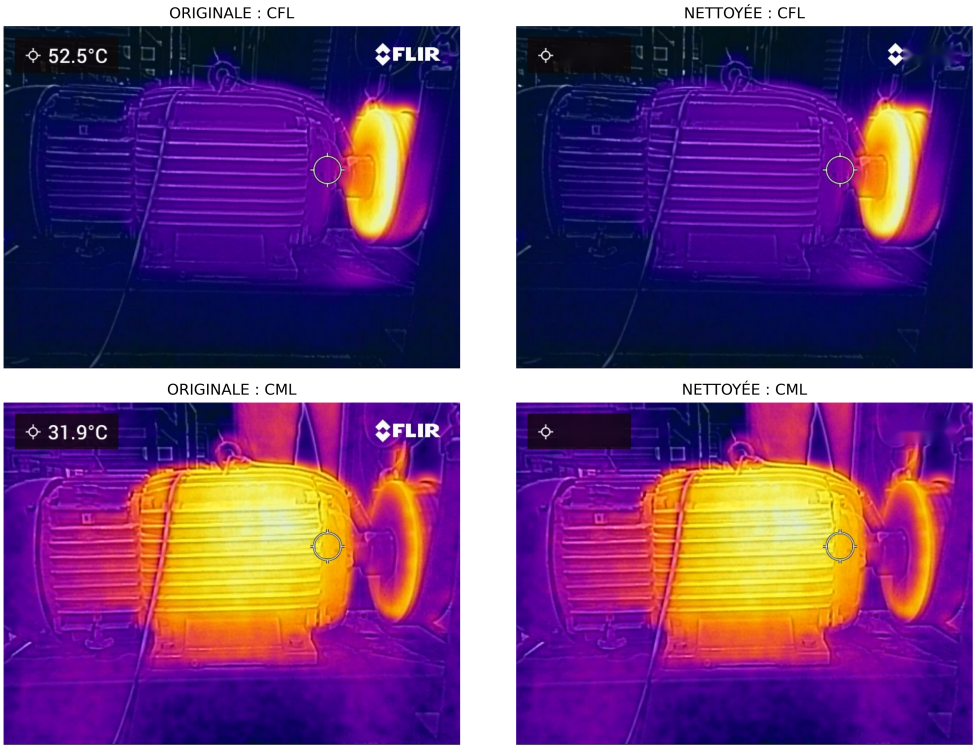

Figure 4.3 : Images originales et images nettoyées. Images de base : *Induction Motor–Thermal Images* [22] ; comparaison du prétraitement de l'étude.

Un masque dont la forme dépend de la classe peut devenir un indice discriminant artificiel. Le traitement doit donc être homogène et conserver un accès à l'image initiale. Les opérations spécifiques à la segmentation, notamment le filtre bilatéral et la définition de la ROI, seront présentées au chapitre 10.

La résolution de l'image exportée ne doit pas être confondue avec celle du détecteur thermique ; les principes de calibration sont établis au chapitre 2. Les limites de la partition de classification sont examinées après les résultats.

4.5 Préparation des données et augmentation conforme à la physique

Le diagnostic sur des machines industrielles réelles se heurte systématiquement à la rareté des jeux de données thermographiques annotés de grande dimension. Le corpus expérimental comprend 488 thermogrammes répartis entre six classes opérationnelles de santé et de charge, ainsi qu'une série de masques de haute précision annotés manuellement par des experts thermiciens.

4.5.1 Élimination du biais de raccourci (Shortcut Bias)

Les caméras thermographiques commerciales incrustent fréquemment des métadonnées alphanumériques dans l'image (températures maximale $T_{\max}$, minimale $T_{\min}$, curseurs de repérage et horodatage). Un réseau convolutif profond est prompt à exploiter ces zones de fort contraste textuel comme raccourci discriminatif, apprenant à « lire » la valeur numérique plutôt qu'à analyser la distribution surfacique de chaleur.

Pour proscrire ce comportement artefactuel, un prétraitement systématique est appliqué :

1. Les zones de texte et métadonnées sont détectées et isolées spatialement à l'aide d'un modèle de reconnaissance optique de caractères (`EasyOCR`).
2. Les masques textuels correspondants sont éliminés et reconstruits par des algorithmes d'inpainting (`cv2.inpaint`), remplaçant les caractères par la valeur radiative locale interpolée des pixels sains environnants.

4.5.2 Augmentation de données guidée par les contraintes thermodynamiques

Contrairement à la vision classique où des transformations géométriques arbitraires sont tolérées, l'imagerie infrarouge d'organes électromécaniques impose des lois physiques strictes de transfert thermique :

— **Proscription du retournement vertical (*Vertical Flip*) :** L'air chaud s'élève par convection naturelle, engendrant un panache thermique préférentiel vers le sommet du carter et des ailettes de ventilation. Inverser l'axe vertical produirait une signature thermique incohérente sur le plan physique.

— **Validation du retournement horizontal (*Horizontal Flip*) :** Le moteur asynchrone présentant une symétrie axiale autour de son arbre de transmission, le retournement selon l'axe horizontal conserve rigoureusement la validité des flux de dissipation thermique.

— **Rotations restreintes :** Application de rotations aléatoires modérées bornées à $\pm 15°$ (ou $\pm 20°$ en régime d'inspection manuelle), émulant les tolérances d'alignement de l'axe optique de la caméra.

— **Homothéties contrôlées (*Zoom*) :** Variations d'échelle bornées à $\pm 10\,\%$ à $\pm 15\,\%$, traduisant les légères fluctuations de distance focale ou de recul en atelier de maintenance.

— **Gigue radiométrique calibrée (*Radiometric Jitter*) :** Injection d'un bruit additif gaussien sur l'intensité normalisée, $\Delta T \sim \mathcal{N}(0; 0{,}02)$, simulant la dérive thermique ambiante et le bruit thermique NETD (*Noise Equivalent Temperature Difference*) du capteur bolométrique.

Ces opérations sont appliquées de manière dynamique (« on-the-fly ») exclusivement sur les données de la partition d'apprentissage ($80\,\%$ du corpus, soit 388 images), garantissant que les partitions de validation et de test (100 images) demeurent rigoureusement vierges de toute corrélation synthétique.

Chapitre 5

Cadre expérimental, reproductibilité et paramétrage des modèles

La reproductibilité des résultats et la transparence algorithmique constituent le fondement d'une validation scientifique rigoureuse en milieu industriel. Ce chapitre formalise l'infrastructure de calcul, l'arbre complet des dépendances logicielles, les mécanismes de préparation et d'augmentation de données respectant les lois thermodynamiques, ainsi que la configuration exhaustive des hyperparamètres régissant les approches markoviennes et connexionnistes.

5.1 Plateformes d'exécution et environnement matériel

L'évaluation et l'entraînement des modèles ont mobilisé deux environnements matériels complémentaires, calibrés pour répondre aux exigences respectives du traitement temps réel en périphérie (*Edge computing*) et du calcul tensoriel intensif :

- **Station de calcul locale (Développement, prétraitement et inférence markovienne) :**
  - **Système d'exploitation :** Ubuntu 22.04 LTS (64 bits, noyau Linux 6.5) et environnement de test sous Windows 11 .
  - **Processeur (CPU) :** Intel Core i5 .
  - **Mémoire vive (RAM) :** 16 Go DDR4/DDR5 haute performance.
  - **Unité de traitement graphique (GPU) :** Carte NVIDIA
  - **Environnement de développement intégré :** Visual Studio Code, gestionnaire d'environnements virtuels isolés (`venv` / `conda`).
- **Infrastructure de calcul accéléré Cloud (Entraînement des réseaux profonds et benchmarks) :**
  - **Plateforme :** Google Colaboratory .
  - **Accélérateur tensoriel :** GPU NVIDIA T4
  - **Plateforme de démonstration continue :** Streamlit Community Cloud pour le déploiement de l'interface d'inspection thermique interactive.

5.2 Socle logiciel, bibliothèques et versions certifiées

L'ensemble des développements applicatifs repose sur Python version 3.10+, garantissant la compatibilité des liaisons C/CUDA et la stabilité numérique. Le tableau 5.1 dresse l'inventaire des composants logiciels mobilisés et de leur fonction au sein du pipeline de traitement.

Table 5.1 : Spécification des frameworks, bibliothèques et rôles opérationnels.

Bibliothèque / Outil	Version minimale	Fonction au sein du système de diagnostic
`Python`	3.10 / 3.11	Interpréteur principal et architecture logicielle modulaire.
`PyTorch (torch)`	2.0.1+cu118	Définition, entraînement par gradient et inférence des architectures CNN et Attention U-Net.
`Torchvision`	0.15.2	Opérations de vision par ordinateur, modèles de référence pré-entraînés et transformations spatiales.
`TensorFlow / Keras`	2.15.0	Entraînement des réseaux de classification de base et extraction des représentations denses.
`OpenCV (cv2)`	4.8.0	Filtrage radiométrique bilatéral, morphologie mathématique et inpainting des artefacts de texte.
`EasyOCR`	1.7.1	Détection optique et localisation des incrustations textuelles pour élimination des biais.
`hmmlearn`	0.3.0	Implémentation de l'algorithme de Baum-Welch (EM) et décodage temporel optimal de Viterbi.
`Scikit-learn`	1.3.0	Classifieurs classiques (SVM, Random Forest, KNN), réduction PCA et calcul des métriques (Dice, AUROC).
`NumPy / SciPy`	1.24.3 / 1.11.1	Algèbre linéaire, calcul de la matrice fondamentale $(I - Q)^{-1}$ et inversion matricielle.
`Streamlit`	1.31.0	Moteur du tableau de bord de supervision et démonstrateur web multi-écrans.

5.3 Description détaillée des hyperparamètres et architectures

5.3.1 Axe 1 : Modèles graphiques probabilistes et markoviens

L'approche markovienne s'articule autour d'une chaîne conjointe combinant régularisation spatiale par champ de Markov (MRF), suivi temporel par modèle caché (HMM) et pronostic de dégradation par chaîne absorbante :

- **Segmentation spatiale par Champ Aléatoire de Markov (MRF) :**
  - Nombre d'états discrets de segmentation : $K = 3$ (zone ambiante / froide, zone tiède suspecte, zone de point chaud critique).
  - Voisinage spatial : 8-connectivité (arêtes cardinales et diagonales).

  - Paramètre d'interaction spatiale (modèle de Potts) : $\beta = 1{,}15$ (calibré pour supprimer les artefacts du capteur sans effacer les discontinuités des bords thermiques).
  - Algorithme d'inférence MAP : Modes Conditionnels Itérés (*Iterated Conditional Modes*, ICM) de Julian Besag. Critère d'arrêt : proportion de pixels modifiés inférieure à 0,1 % de l'image ou seuil maximal de 15 itérations (convergence typique observée entre 6 et 10 itérations).
- **Suivi temporel par Modèle de Markov Caché (HMM) :**
  - États cachés sous-jacents : 4 classes de santé (S_1 : Normal, S_2 : Suspect, S_3 : Confirmé, S_4 : Critique).
  - Vecteur d'observations continues ($\mathbf{o}_t \in \mathbb{R}^5$) : température maximale $T_{\max}$, gradient relatif $\Delta T = T_{\max} - T_{\text{amb}}$, surface de la région chaude S_{hot}, gradient thermique frontal et indice de dissymétrie mécanique.
  - Modèle d'émission : Distribution gaussienne multivariée continue à matrice de covariance diagonale régularisée ($\epsilon = 10^{-3}$).
  - Entraînement et décodage : Algorithme espérance-maximisation (EM / Baum-Welch) plafonné à 50 itérations ; alignement de la trajectoire la plus probable via l'algorithme de Viterbi.
- **Pronostic par Chaîne de Markov Absorbante :**
  - Définition structurelle : L'état S_4 (Critique) est configuré comme état absorbant terminal ($P_{44} = 1$).
  - Matrice fondamentale : Résolution analytique directe de $\mathbf{N} = (\mathbf{I} - \mathbf{Q})^{-1}$, où $\mathbf{Q} \in \mathbb{R}^{3\times3}$ gouverne les états transitoires.
  - Horizon de projection : Analyse de défaillance à horizon fini $h \in [1, 50]$ trames. Seuil de criticité d'intervention fixé à $P_{\text{panne}}(h) \geq 0{,}65$.

5.3.2 Axe 2 : Réseaux de neurones convolutifs (CNN et Attention U-Net)

Les architectures profondes ont été dimensionnées avec des structures légères afin de prévenir tout surapprentissage sur corpus réduit :

- **Segmentation par Attention U-Net :**
  - Structure de l'encodeur : 4 blocs convolutifs à canaux réduits ($16 \to 32 \to 64 \to 128$) couplés à une normalisation par lot (*Batch Normalization*) et des activations ReLU.
  - Goulot d'étranglement (*Bottleneck*) : 256 canaux avec couche de *Spatial Dropout* ($p = 0{,}1$).
  - Décodeur : Blocs de déconvolution (*ConvTranspose2d*) avec portes d'attention intégrant les connexions résiduelles (*skip connections*).
  - Régime d'apprentissage : Optimiseur AdamW ($\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, pénalité de poids $L_2 = 1 \times 10^{-4}$), taux d'apprentissage initial $\eta_0 = 1 \times 10^{-3}$ avec recuit cosinusoïdal, 35 époques, taille de lot (*batch size*) fixée à 4 pour des tenseurs de résolution 128×128 pixels.

— Fonction de perte combinée :

$$\mathcal{L}_{\text{total}} = 0{,}5\,\mathcal{L}_{\text{BCE}} + 0{,}5\,\mathcal{L}_{\text{Dice}} \tag{5.1}$$

— **Classification directe et modèles hybrides (DenseNet121 / MobileNetV2) :**

— Format des tenseurs d'entrée : $224 \times 224 \times 3$, normalisation radiométrique ImageNet.

— Optimiseur : Adam ($\eta = 1 \times 10^{-4}$ en phase de réglage fin / *fine-tuning*), taille de lot de 16 ou 32, 25 à 30 époques.

— Mécanisme d'arrêt précoce (*Early Stopping*) : Surveillance de la perte de validation avec une patience de 5 époques.

— Modèles hybrides : Extraction des vecteurs d'embeddings (dimension 1024 en sortie de DenseNet121 sans couche dense terminale) couplée à un classifieur Random Forest ($n_{\text{estimators}} = 200$, critère de Gini) ou un SVM à noyau RBF ($C = 10{,}0$, échelle γ automatique).

Quatrième partie

Comparaison des méthodes de classification

Chapitre 6

Classification directe par réseaux convolutifs

6.1 Principe d'un CNN

Un **réseau de neurones convolutif** apprend des filtres locaux partagés [1]. Pour une carte d'entrée X, un noyau K et un biais b, une activation s'écrit schématiquement :

$$Y_{i,j,k} = \phi\left(\sum_{u,v,c} K_{u,v,c,k} X_{i+u,j+v,c} + b_k\right), \tag{6.1}$$

où ϕ est généralement ReLU. Les premières couches détectent contours et gradients ; les couches profondes combinent ces motifs en signatures spatiales. Le pooling réduit la résolution et le coût de calcul, tandis que Softmax transforme les logits finaux en probabilités de classe.

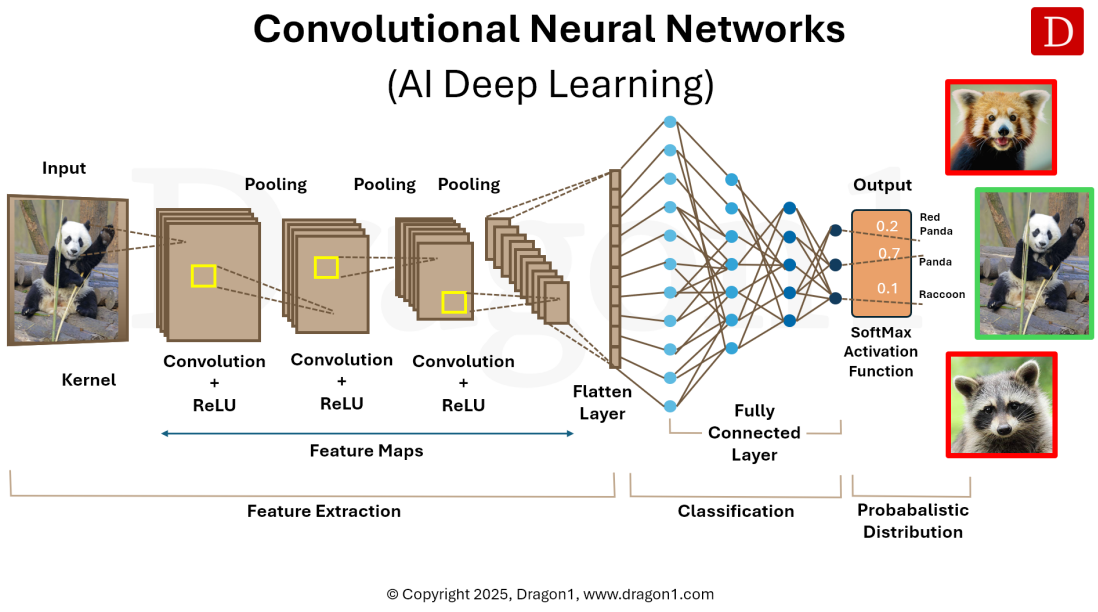

Figure 6.1 : Chaîne conceptuelle d'un réseau convolutif, de l'image aux probabilités. Source : Dragon1 [39].

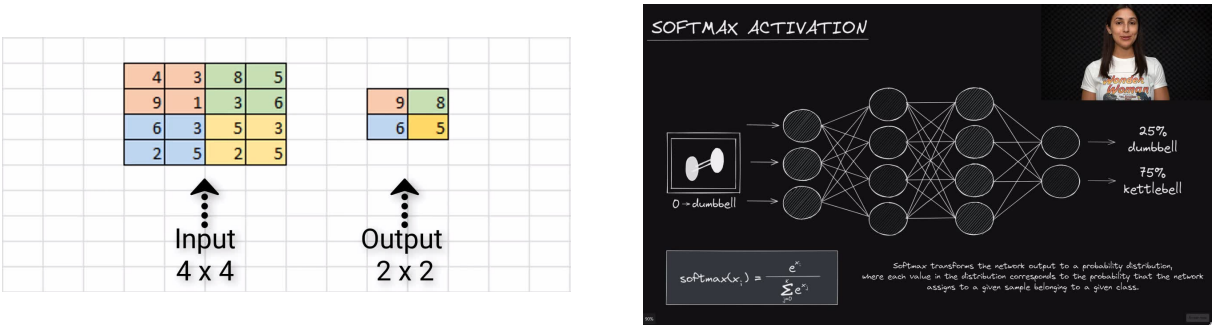

Figure 6.2 : Réduction par max-pooling (à gauche) et transformation Softmax des sorties (à droite). Source : deeplizard [40].

6.2 CNN personnalisé

Le CNN de référence comporte trois blocs `Conv2D + MaxPooling` de 32, 64 et 128 filtres, suivis d'un aplatissement, d'une couche dense de 128 neurones, d'un dropout de 0,5 et d'une sortie Softmax à six neurones. Cette architecture est cohérente avec un petit dataset, mais l'aplatissement produit une tête dense plus paramétrique qu'un *global average pooling*.

```
model = Sequential([
    Conv2D(32, 3, activation="relu", input_shape=(224, 224, 3)),
    MaxPooling2D(),
    Conv2D(64, 3, activation="relu"),
    MaxPooling2D(),
    Conv2D(128, 3, activation="relu"),
    MaxPooling2D(),
    Flatten(),
    Dense(128, activation="relu"),
    Dropout(0.5),
    Dense(6, activation="softmax")
])
```

Listing 6.1: Architecture conceptuelle du CNN personnalisé

Le **dropout** réduit la coadaptation des neurones [9]. L'optimiseur Adam et la perte catégorielle sont adaptés, mais le protocole doit aussi préciser le taux d'apprentissage, la taille de lot, le nombre d'époques, l'early stopping et les graines aléatoires.

6.3 Transfert d'apprentissage

Le transfert d'apprentissage réutilise un réseau pré-entraîné, généralement sur ImageNet, comme extracteur de caractéristiques. La procédure recommandée est :

1. charger le backbone et son prétraitement natif ;
2. geler ses poids et entraîner une nouvelle tête ;
3. dégeler une partie des couches supérieures ;
4. poursuivre avec un taux d'apprentissage faible.

Cette stratégie est celle décrite par la documentation TensorFlow pour les petits jeux de données [27]. Le **gel des paramètres** ne garantit toutefois pas la pertinence des carac-

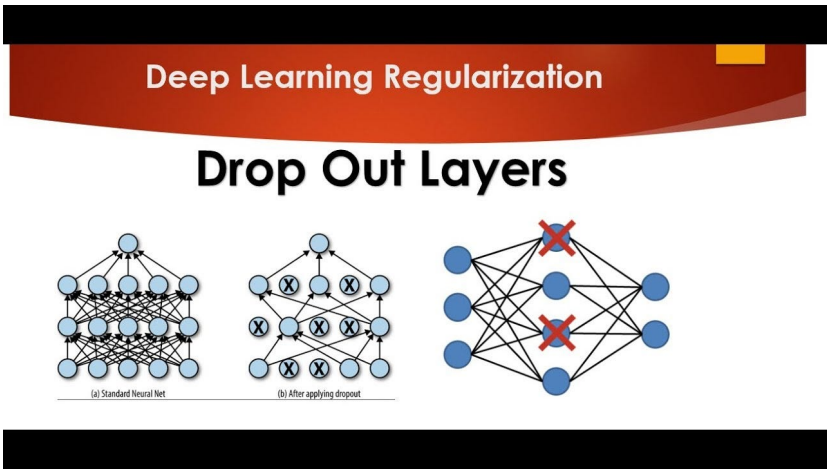

Figure 6.3 : Principe du dropout : désactivation aléatoire d'une fraction des neurones pendant l'entraînement. Source : Towards Data Science [41].

téristiques : des images thermiques pseudo-colorées diffèrent fortement des photographies ImageNet.

6.4 Architectures comparées

Table 6.1 : Profil des cinq architectures directes

Architecture	Idée principale	Intérêt attendu
CNN personnalisé	Trois blocs convolutifs entraînés de zéro	Baseline contrôlable
MobileNetV2	Convolutions séparables et résidus inversés [6]	Faible coût embarqué
ResNet50	Connexions résiduelles profondes [5]	Extracteur puissant
EfficientNetB0	Mise à l'échelle composée et blocs MBConv [7]	Efficacité paramétrique
DenseNet121	Connexions denses et réutilisation des caractéristiques [8]	Bonne propagation de l'information

Chapitre 7

Approche hybride CNN et Machine Learning

7.1 Architecture générale

L'approche hybride sépare la représentation visuelle et la décision. Le CNN, privé de sa tête Softmax, transforme chaque image I_i en vecteur $z_i = f_\theta(I_i)$. Les couples (z_i, y_i) alimentent ensuite un classifieur classique g :

$$\widehat{y}_i = g(f_\theta(I_i)) \,. \tag{7.1}$$

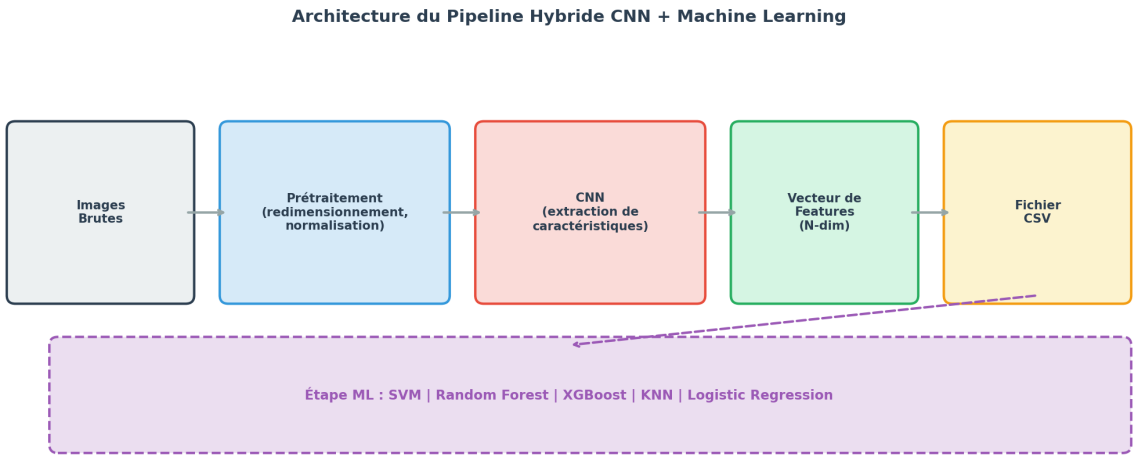

Figure 7.1 : Pipeline hybride : prétraitement, extraction CNN, stockage des caractéristiques et classification. Source : inspirée d'une architecture hybride CNN–Random Forest [42].

Le découplage permet de réutiliser les mêmes caractéristiques pour plusieurs classifieurs et facilite l'analyse. Le fichier CSV doit conserver l'identifiant de l'image, le groupe d'acquisition, le label et la version de l'extracteur afin d'assurer la traçabilité.

7.2 Classifieurs évalués

7.2.1 Support Vector Machine

Le SVM maximise la **marge** entre classes. Un noyau RBF peut modéliser des frontières non linéaires, avec deux hyperparamètres majeurs : C et γ. La standardisation est généra-

lement nécessaire lorsque les caractéristiques n'ont pas la même échelle ; ses paramètres sont ajustés sur l'entraînement uniquement.

7.2.2 Random Forest

La **forêt aléatoire** agrège des arbres entraînés sur des échantillons bootstrap et des sous-ensembles de variables. Elle tolère les relations non linéaires, requiert peu de mise à l'échelle et fournit des importances de variables, bien que celles-ci soient difficiles à relier directement à des zones de l'image.

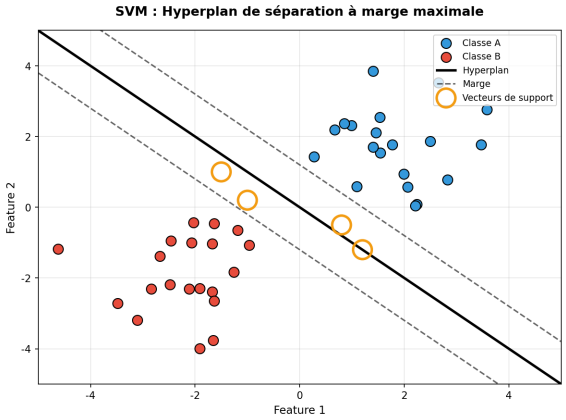

SVM et hyperplan à marge maximale

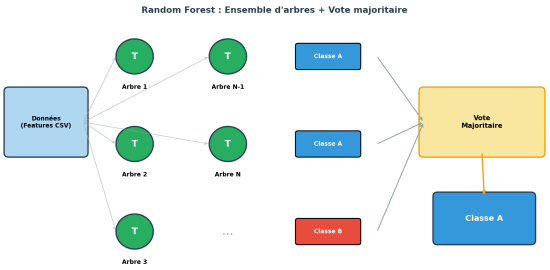

Vote d'une forêt aléatoire

Figure 7.2 : Représentations pédagogiques du SVM et du Random Forest. Sources : scikit-learn [30] et MLU-Explain [43].

7.2.3 XGBoost

XGBoost construit séquentiellement des arbres qui corrigent les résidus des précédents. Sa performance dépend fortement de la profondeur, du taux d'apprentissage, du nombre d'arbres et de la régularisation. Sur seulement 388 vecteurs d'entraînement, une optimisation trop poussée peut suradapter la validation.

7.2.4 K plus proches voisins

KNN attribue la classe majoritaire parmi les K vecteurs les plus proches. Il est simple, mais sensible à l'échelle et à la dimension. Le succès de DenseNet121+KNN indique que l'espace DenseNet sépare bien les six états sur la partition expérimentale.

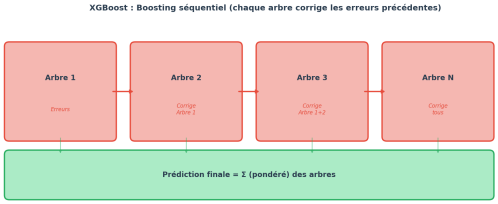

Construction séquentielle de XGBoost

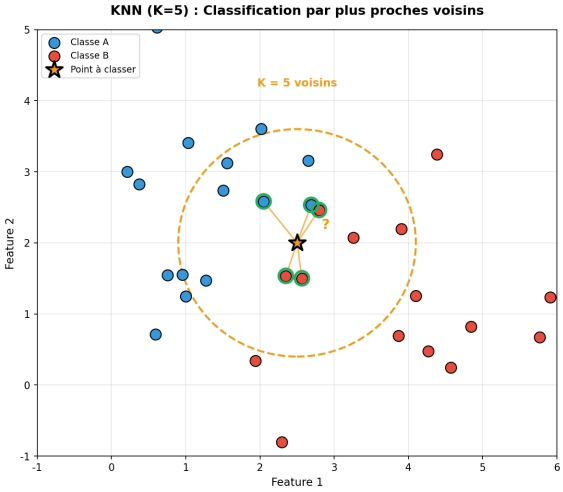

Classification par voisins proches

Figure 7.3 : Représentations pédagogiques de XGBoost et de KNN. Sources : documentation XGBoost [31] et IBM [32].

7.2.5 Régression logistique

La régression logistique multiclasse apprend des frontières linéaires dans l'espace de caractéristiques. Sa proximité avec des modèles plus complexes peut signifier que l'extracteur a déjà produit une représentation presque linéairement séparable.

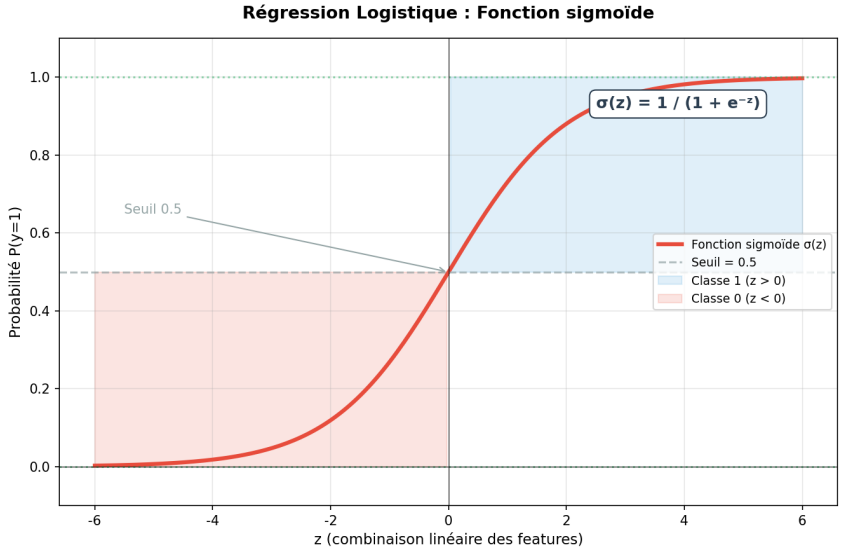

Figure 7.4 : Fonction sigmoïde utilisée par la régression logistique binaire. .

Table 7.1 : Comparaison pratique des classifieurs hybrides

Modèle	Atout	Limite	Mise à l'échelle
SVM	Marge robuste en grande dimension	Coût et réglage du noyau	Oui
Random Forest	Peu de préparation, non-linéaire	Modèle volumineux	Non indispensable
XGBoost	Forte capacité sur données tabulaires	Réglage et surapprentissage	Non indispensable
KNN	Simple, aucune phase paramétrique	Coût à l'inférence, dimension	Oui
Logistique	Rapide et interprétable	Frontière linéaire	Oui

7.3 Métriques

Pour chaque classe traitée en un-contre-tous :

$$\text{Précision} = \frac{VP}{VP + FP}, \qquad \text{Rappel} = \frac{VP}{VP + FN}, \tag{7.2}$$

$$F_1 = \frac{2\,\text{Précision}\,\text{Rappel}}{\text{Précision} + \text{Rappel}}. \tag{7.3}$$

L'exactitude est la proportion globale de prédictions correctes. Le **F1 macro** moyenne les six F1 sans pondération, ce qui évite que HFL domine l'évaluation. La matrice de confusion C_{ij} compte les images de classe réelle i prédites j [28].

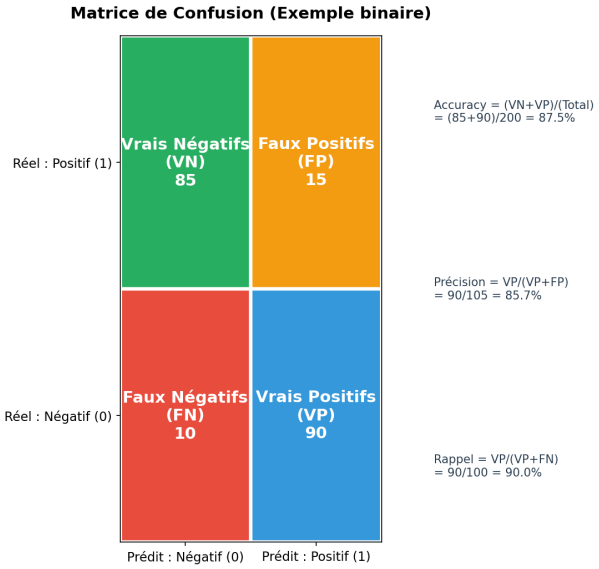

Figure 7.5 : Lecture pédagogique d'une matrice de confusion binaire. .

Pour une application de maintenance, la gravité des erreurs peut être asymétrique : confondre un état corrodé avec un état sain peut coûter davantage que l'erreur inverse. Une métrique pondérée par le risque métier devrait compléter le F1 macro.

Chapitre 8

Résultats expérimentaux consolidés

8.1 CNN directs

Le tableau 8.1 présente les performances mesurées sur les 100 images de validation. Les métriques de précision, rappel et F1 sont des moyennes macro.

Table 8.1 : Performances des CNN directs sur les 100 images de validation

Modèle	Exactitude	Précision	Rappel	F1 macro
CNN personnalisé	0,90	0,94	0,90	0,90
MobileNetV2	**0,94**	**0,96**	**0,93**	**0,94**
ResNet50	0,23	0,04	0,17	0,06
EfficientNetB0	0,23	0,04	0,17	0,06
DenseNet121	0,92	0,93	0,90	0,90

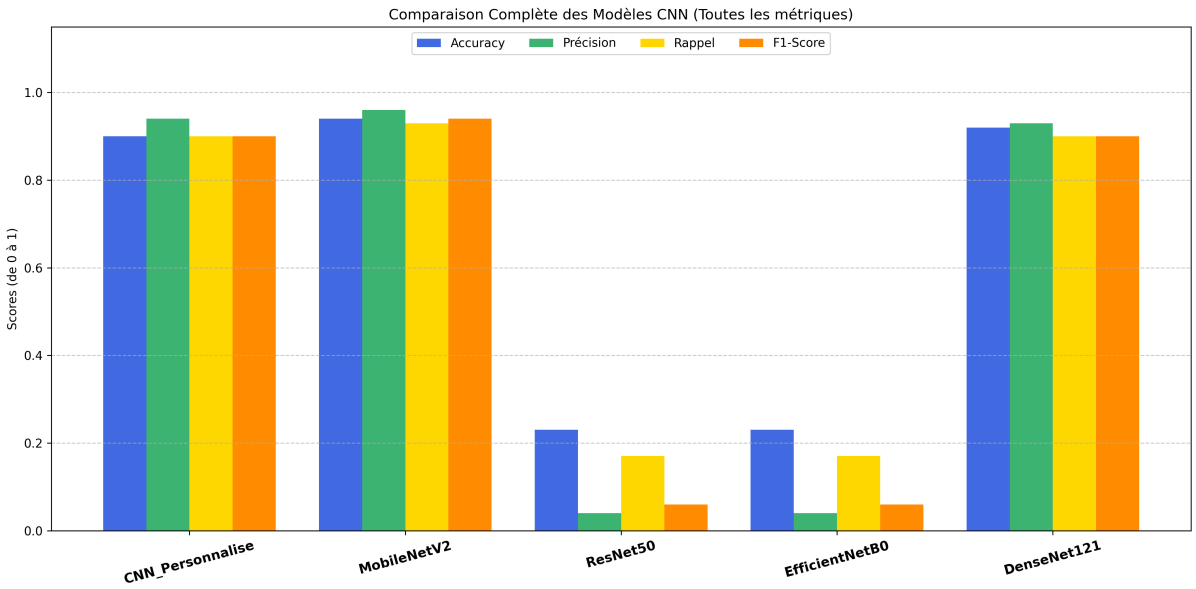

Figure 8.1 : Comparaison des cinq CNN directs.

MobileNetV2 est le meilleur CNN direct sur cette partition. Son rapport par classe montre des F1 de 0,89 pour CFL, 0,94 pour CML, 1,00 pour CNL, 0,92 pour HFL, 0,87 pour HML et 1,00 pour HNL. Les erreurs se concentrent donc dans la distinction des régimes chargés, en particulier HML.

Le CNN personnalisé obtient 90 % mais son rappel HML n'est que de 0,41. ResNet50 et EfficientNetB0 prédisent toutes les images en HFL, soit exactement la fréquence de la

classe majoritaire dans la validation (23/100). Ce comportement est compatible avec un problème d'entraînement ou de prétraitement, sans en établir à lui seul la cause.

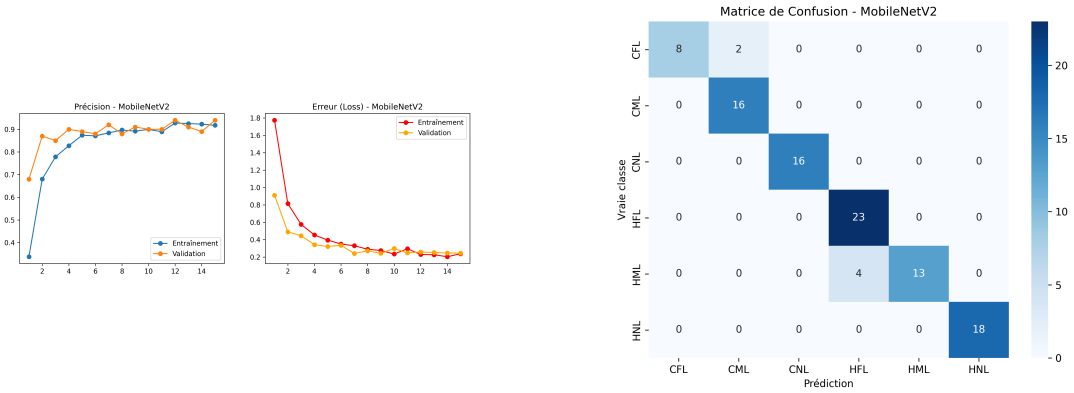

Figure 8.2 : MobileNetV2 : courbes d'apprentissage et matrice de confusion.

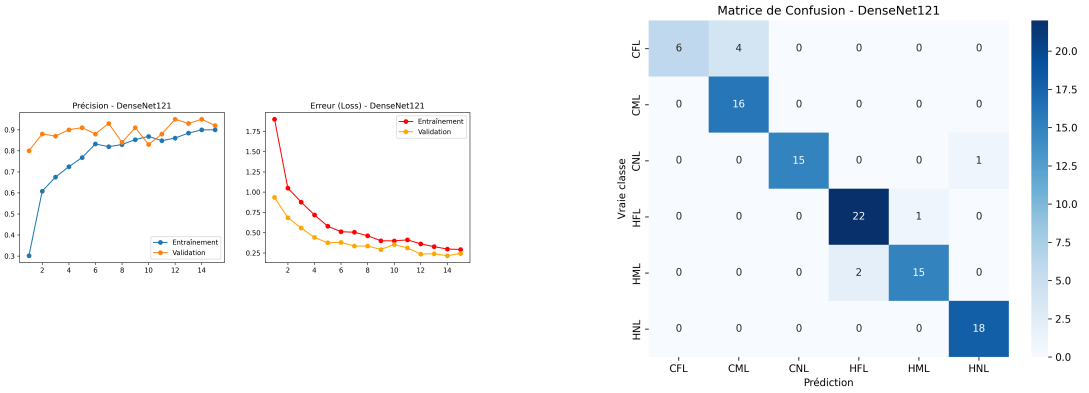

Figure 8.3 : DenseNet121 direct : courbes d'apprentissage et matrice de confusion.

8.2 Modèles hybrides

Vingt combinaisons ont été évaluées : quatre extracteurs pré-entraînés et cinq classifieurs. Le tableau 8.2 présente les dix premières.

DenseNet121+KNN et DenseNet121+Random Forest produisent exactement le même rapport : 98 bonnes prédictions sur 100. Les deux erreurs correspondent à des images HML prédites HFL ; toutes les classes corrodées et HNL sont correctement reconnues.

8.3 Comparaison finale

Le meilleur hybride dépasse MobileNetV2 direct de quatre points d'accuracy et de F1 macro. L'écart correspond à quatre images sur le jeu de validation. Avec seulement 100

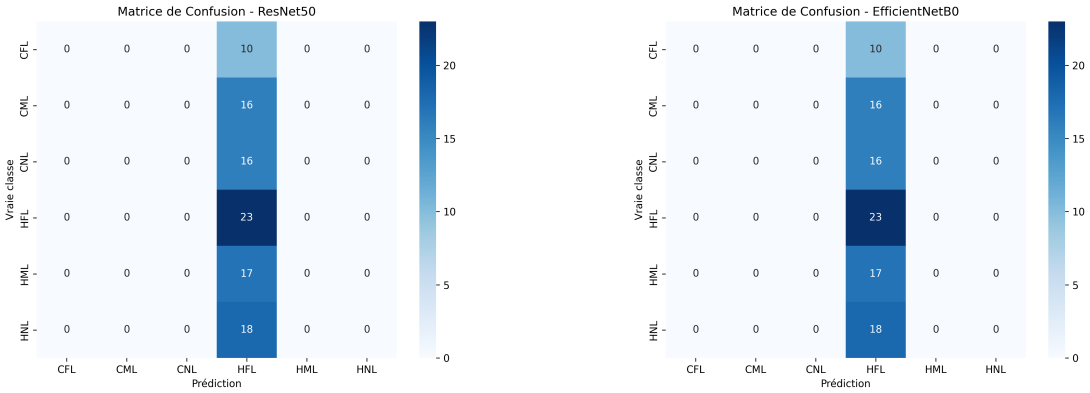

ResNet50 EfficientNetB0

Figure 8.4 : Concentration des prédictions de ResNet50 et EfficientNetB0 sur la classe HFL dans cette expérience.

Table 8.2 : Dix meilleures combinaisons hybrides

Modèle	Exactitude	Précision	Rappel	F1 macro
DenseNet121 + KNN	0,98	0,99	0,98	0,98
DenseNet121 + Random Forest	0,98	0,99	0,98	0,98
DenseNet121 + SVM	0,97	0,98	0,97	0,97
MobileNetV2 + régression logistique	0,97	0,98	0,97	0,97
DenseNet121 + régression logistique	0,97	0,98	0,96	0,97
MobileNetV2 + KNN	0,97	0,98	0,97	0,97
MobileNetV2 + SVM	0,96	0,97	0,97	0,97
MobileNetV2 + Random Forest	0,95	0,96	0,96	0,96
DenseNet121 + XGBoost	0,95	0,96	0,95	0,95
ResNet50 + XGBoost	0,93	0,94	0,94	0,94

observations et sans répétition, il ne faut pas présenter cette différence comme statistiquement établie. Un intervalle de confiance ou un test apparié sur plusieurs splits groupés serait nécessaire.

8.4 Enseignements

- DenseNet121 fournit les caractéristiques les plus séparables dans ce protocole.
- KNN et Random Forest atteignent le même maximum, ce qui réduit l'argument en faveur d'un classifieur complexe.
- MobileNetV2 est le meilleur compromis pour un CNN direct léger.
- HML et HFL sont les classes les plus fréquemment confondues ; la charge paraît plus difficile à séparer que l'état sain/corrodé.
- Les effondrements d'EfficientNetB0 et de ResNet50 doivent faire l'objet d'un diagnostic technique avant toute conclusion architecturale.

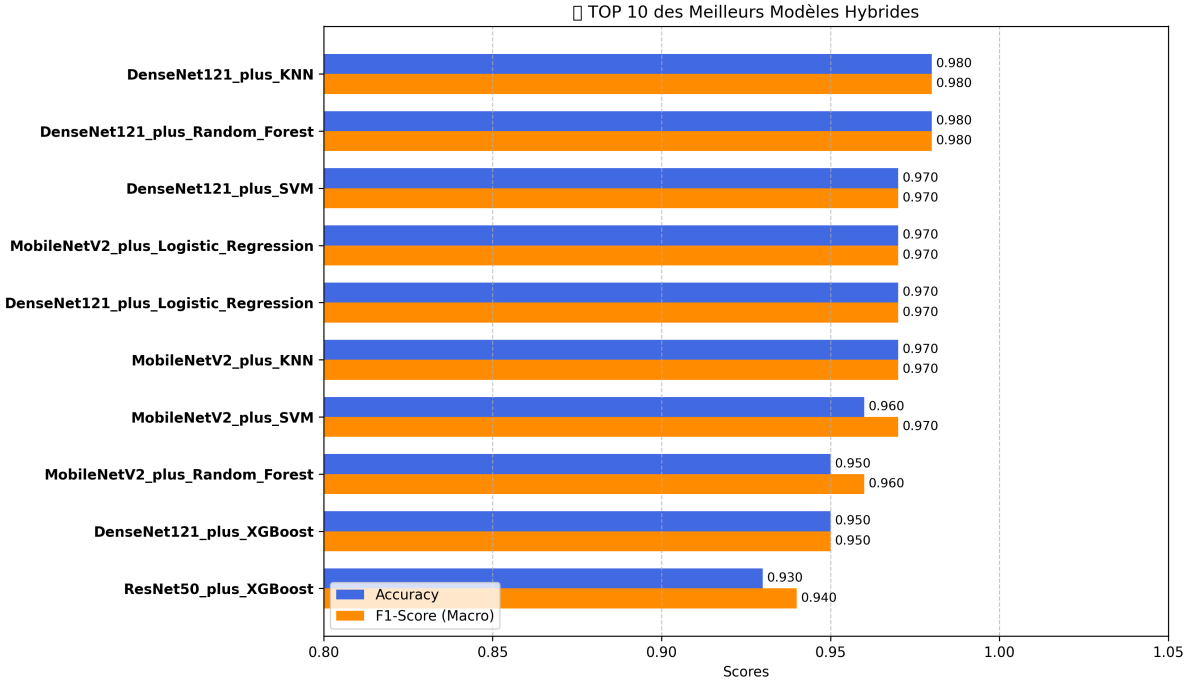

Figure 8.5 : Classement des dix meilleurs modèles hybrides.

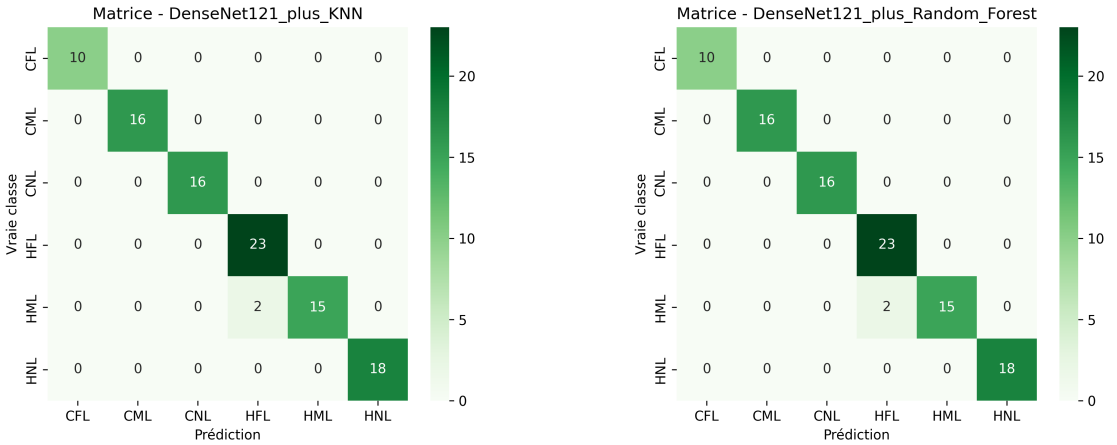

DenseNet121 + KNN DenseNet121 + Random Forest

Figure 8.6 : Matrices de confusion des deux meilleurs modèles hybrides.

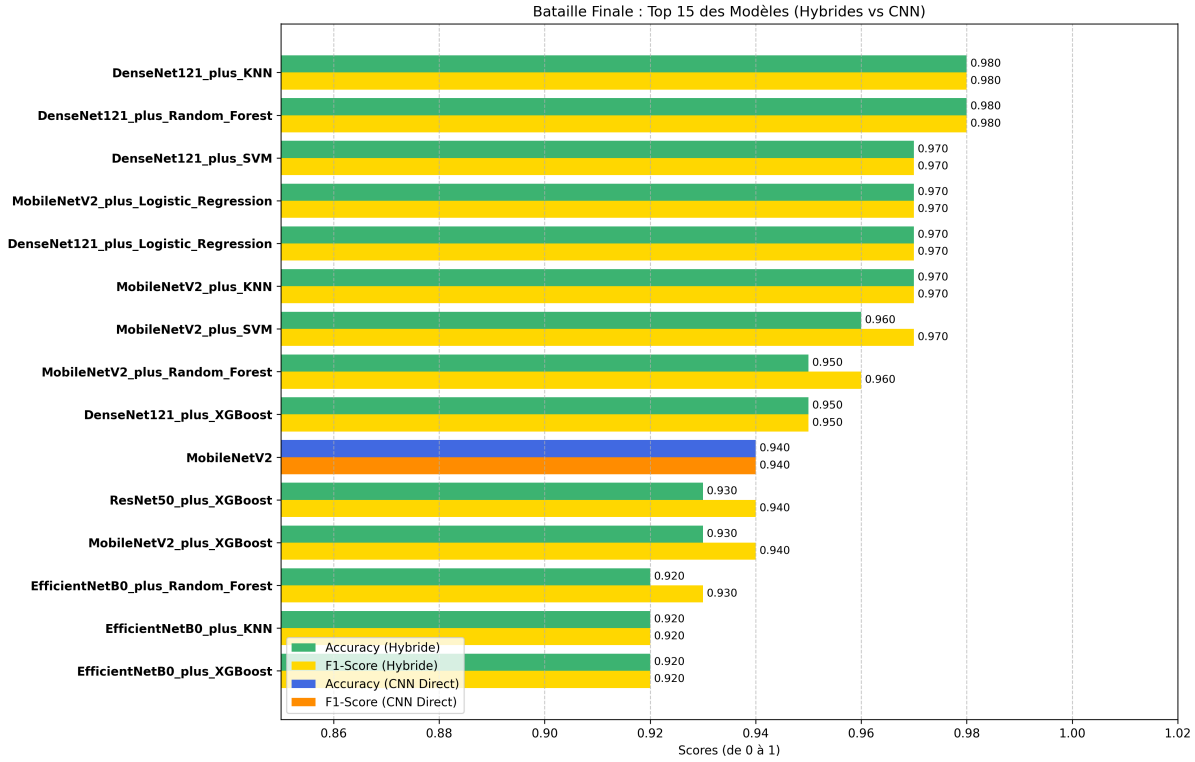

Figure 8.7 : Classement final des quinze meilleurs modèles directs et hybrides.

Cinquième partie

Localisation, suivi temporel et aide à la maintenance

Chapitre 9

Architecture du diagnostic spatio-temporel

9.1 De la classe d'image à l'état suivi

Les limites de la reconnaissance image par image conduisent à distinguer la localisation d'une région, la description de ses propriétés et l'évolution de l'état de santé. Les fondements de l'apprentissage visuel et les jeux de données étant établis dans la première partie, l'objectif est désormais de construire une **chaîne d'interprétation cohérente**.

Question directrice. Où se situe la région à surveiller, comment évolue-t-elle et quel risque le modèle lui associe-t-il à un horizon donné ?

L'axe probabiliste associe un **MRF spatial**, des mesures interprétables, un **HMM temporel** et un calcul d'absorption. L'axe profond associe un **U-Net**, une représentation du contexte et un traitement de la durée. Le U-Net et le CNN contextuel constituent des branches parallèles, et non deux opérations qui devraient nécessairement être exécutées en série.

9.2 Interfaces entre les traitements

Table 9.1 : Informations transmises entre les principales étapes

Étape	Entrée	Sortie
Acquisition	Image, horodatage, contexte	Enregistrement identifié
Prétraitement	Image et région machine	Image préparée, ROI
Localisation	Image préparée	Masque ou probabilités spatiales
Description	Région sélectionnée	Intensité, contraste, aire, position
Suivi	Observations ordonnées	État et incertitude, durée éventuelle
Anticipation	État présent et modèle dynamique	Risque à horizon fini
Décision	Risque, qualité, contexte	Alerte justifiée ou abstention

L'identifiant d'un fichier, sa position dans une séquence et son temps physique sont trois informations différentes. Le nom `316.bmp` ne définit pas, à lui seul, une durée de 316 secondes. Les unités et les règles de remise à zéro du suivi doivent rester cohérentes d'une étape à l'autre.

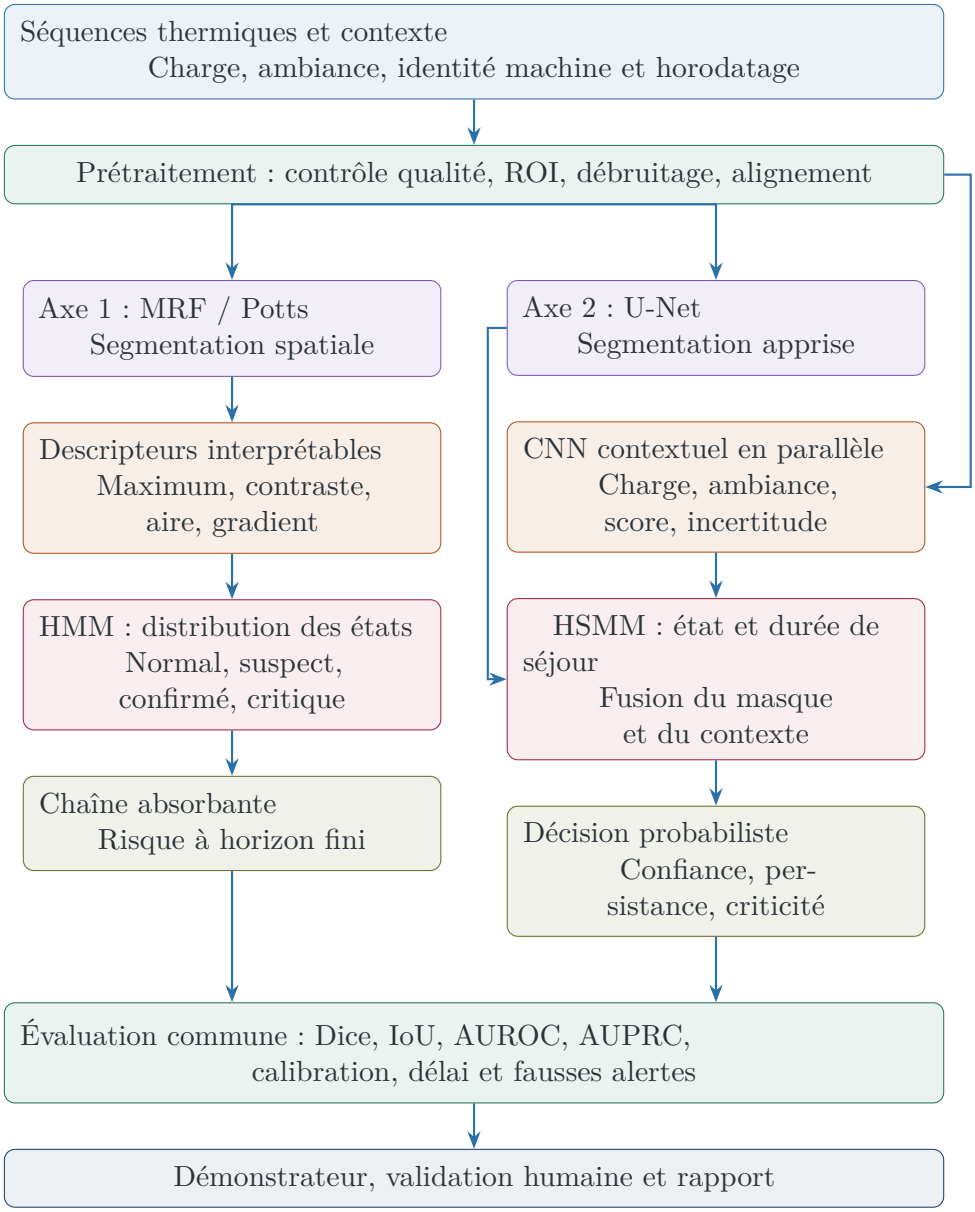

Figure 9.1 : Architecture fonctionnelle cible : deux axes complémentaires et une évaluation commune. Schéma de synthèse du projet.

9.3 Continuité de l'interprétation

La segmentation peut être comparée à un surlignage : elle désigne ce qui sera mesuré. Les descripteurs caractérisent cette sélection. Le suivi conserve une mémoire de son évolution et l'anticipation projette l'état estimé sous des hypothèses explicites. Cette lecture souligne pourquoi une erreur de localisation peut se propager jusqu'à l'alerte.

9.4 Modèles stochastiques : Comprendre les concepts de MRF, HMM et HSMM

Pour modéliser l'incertitude inhérente aux mesures physiques sans recourir à un apprentissage de type « boîte noire », ce travail exploite la famille des modèles graphiques probabilistes. Contrairement aux approches purement inductives, les modèles markoviens imposent des contraintes de continuité spatiale et de causalité thermodynamique. Trois formalisations complémentaires sont mobilisées.

9.4.1 Le Champ Aléatoire de Markov (MRF) : La cohérence spatiale dans l'image

Dans une image infrarouge, chaque pixel traduit une mesure scalaire de rayonnement. Toutefois, un capteur bolométrique non refroidi génère un bruit granulaire intrinsèque (bruit NETD), créant parfois des pixels isolés faussement surchauffés. Physiquement, la conduction thermique impose qu'un pixel sain entouré de matière froide ne puisse pas constituer une source chaude ponctuelle sans transfert progressif vers ses voisins.

Le Champ Aléatoire de Markov spatial (*Markov Random Field*, MRF) modélise cette contrainte en représentant l'image sous la forme d'un graphe non orienté en grille bidimensionnelle (Figure 9.2). Chaque site s porte deux variables :

— Une observation radiométrique continue y_s (la température mesurée) ;
— Une étiquette discrète cachée $x_s \in \{0 : \text{Ambiant}, 1 : \text{Suspect}, 2 : \text{Critique}\}$.

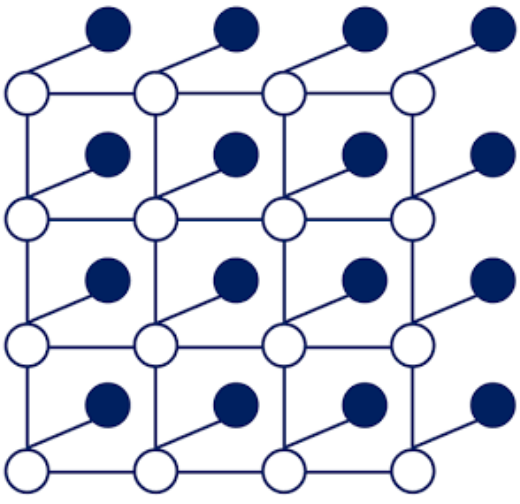

Figure 9.2 : Représentation en grille d'un champ de Markov spatial (MRF). Les sites blancs représentent les étiquettes de segmentation latentes couplées à leur voisinage spatial, et les nœuds foncés représentent les pixels thermiques observés (Source : [44]).

Selon la propriété markovienne locale, l'état d'un pixel ne dépend que de ses voisins immédiats $\mathcal{V}(s)$:

$$P(x_s \mid x_{S\setminus\{s\}}) = P(x_s \mid x_r,\, r \in \mathcal{V}(s)) \tag{9.1}$$

En vertu du théorème de Hammersley-Clifford, la distribution globale suit une loi de Gibbs $P(X \mid Y) \propto \exp(-U(X,Y))$. L'énergie globale U pénalise les ruptures spatiales incohérentes à travers le modèle de Potts régularisé par le paramètre β :

$$U(X,Y) = \sum_{s \in S} \left[\frac{(y_s - \mu_{x_s})^2}{2\sigma_{x_s}^2} + \ln(\sqrt{2\pi}\sigma_{x_s}) \right] + \beta \sum_{\{s,r\} \in \mathcal{C}} (1 - \delta(x_s, x_r)) \tag{9.2}$$

L'inférence par l'algorithme des Modes Conditionnels Itérés (*ICM*) converge rapidement vers une segmentation nettoyée du bruit de mesure.

9.4.2 Le Modèle de Markov Caché (HMM) : La trajectoire temporelle de santé

Une fois les régions d'intérêt isolées par le MRF, la surveillance ne s'arrête pas à une image statique : l'état du moteur évolue dans le temps sous forme de séquence vidéo. Un pic thermique furtif peut résulter d'un simple transitoire de démarrage sans pour autant signifier que le roulement est endommagé.

Le Modèle de Markov Caché (*Hidden Markov Model*, HMM) répond à cette problématique en découplant l'état de santé effectif de la machine de ses manifestations mesurables (Figure 9.3) :

— L'état de dégradation $S_t \in \{S_1 : \text{Normal}, S_2 : \text{Suspect}, S_3 : \text{Confirmé}, S_4 : \text{Critique}\}$ est latent (inaccessible directement) ;

— Le vecteur d'observation $\mathbf{o}_t$ regroupe des grandeurs physiques calculées sur le masque (température maximale $T_{\max}$, gradient ΔT, dissymétrie mécanique) ;

— La matrice de transition $A_{ij} = P(S_{t+1} = j \mid S_t = i)$ impose une structure gauche-droite interdisant les retours spontanés d'un état usé vers un état neuf.

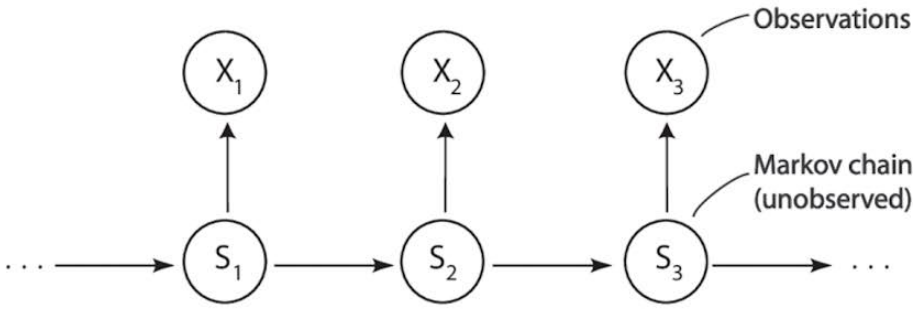

Figure 9.3 : Chaîne de Markov Cachée temporelle (HMM). L'évolution de l'état de santé latent S_t pilote stochastiquement les observations physiques continues $\mathbf{o}_t$ (Source : [45]).

L'algorithme de Viterbi calcule analytiquement la trajectoire d'états la plus vraisemblable $\hat{S}_{1:T}$, filtrant les fausses alertes transitoires sans retarder l'alerte sur dérive lente.

9.4.3 Le Modèle Semi-Markovien Caché (HSMM) : La prise en compte du temps de séjour

Le HMM standard souffre d'une limitation thermodynamique majeure : la propriété sans mémoire implique que la durée de séjour dans un état i suit implicitement une loi géométrique décroissante :

$$P(d) = (A_{ii})^{d-1}(1 - A_{ii}) \tag{9.3}$$

Cette formulation stipule que la probabilité de quitter un état est maximale dès le premier instant, ce qui est physiquement faux pour l'échauffement d'un roulement industriel possédant une inertie thermique et une constante de temps propre $\tau = R_{\text{th}}C_{\text{th}}$.

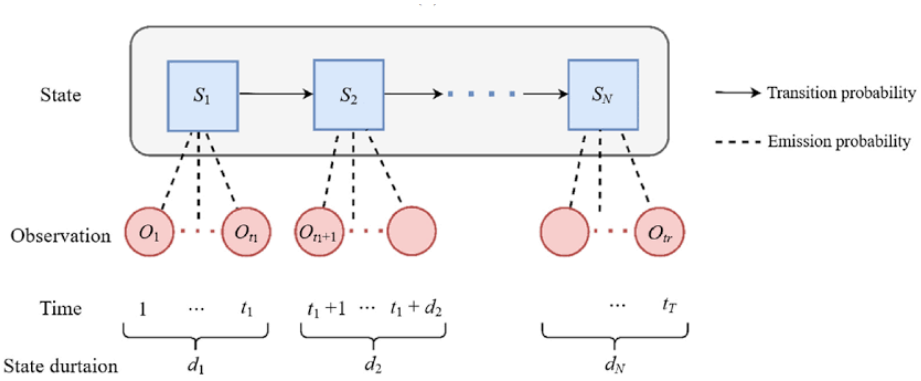

Figure 9.4 : Modèle Semi-Markovien Caché (HSMM). Chaque macro-état S_i est explicitement associé à une loi de distribution de durée de séjour d_i régissant le nombre d'observations émises avant toute transition d'état (Source : [46]).

Le Modèle Semi-Markovien Caché (*Hidden Semi-Markov Model*, HSMM) lève cette restriction en associant explicitement à chaque état une loi de séjour paramétrique $p_i(d)$ (par exemple une loi de Weibull ou une loi Gamma) (Figure 9.4). Le système ne peut transiter vers l'état suivant qu'une fois la durée de séjour écoulée, modélisant avec fidélité la cinétique de fatigue des matériaux et l'accumulation de chaleur.

Chapitre 10

Prétraitement spatial et construction des observations

10.1 Descripteurs physiques interprétables

Pour une région thermique d'intérêt M non vide et une zone de référence saine B non vide, le vecteur d'observation regroupe les descripteurs caractéristiques suivants :

$$T_{\max,M} = \max_{p \in M} T(p), \qquad \Delta T = \frac{1}{|M|} \sum_{p \in M} T(p) - \frac{1}{|B|} \sum_{p \in B} T(p), \tag{10.1}$$

$$A = |M|, \qquad r_A = \frac{|M|}{|\mathrm{ROI}|}, \quad \bar{x} = \frac{1}{|M|} \sum_{p \in M} x_p, \quad \bar{y} = \frac{1}{|M|} \sum_{p \in M} y_p. \tag{10.2}$$

La température maximale $T_{\max,M}$ et l'écart relatif ΔT caractérisent l'intensité thermodynamique du phénomène ; l'aire A, le ratio de surface r_A et le barycentre spatial $(\bar{x}, \bar{y})$ décrivent respectivement l'extension surfacique et la localisation du point chaud. Un gradient calculé aux frontières complète cette description par une mesure de diffusion locale. En l'absence de calibration radiométrique absolue, ces grandeurs expriment des contrastes et des intensités normalisés.

10.2 Indicateur synthétique de santé

Ces caractéristiques physiques sont agrégées au sein d'un indicateur scalaire composite borné :

$$H = \sum_{k=1}^{K} w_k \, \mathrm{clip}(z_k, 0, 1), \qquad \text{avec } w_k \geq 0 \quad \text{et} \quad \sum_{k=1}^{K} w_k = 1. \tag{10.3}$$

Les coefficients w_k pondèrent l'influence relative de chaque variable z_k préalablement normalisée. Cet indice $H \in [0, 1]$ reflète la sévérité thermique instantanée sans constituer à lui seul une probabilité formelle de rupture ; la conversion de cette observation en croyance sur l'état de santé effectif est déléguée aux modèles dynamiques temporels.

Chapitre 11

Modélisation probabiliste et anticipation du risque

11.1 Probabilité et mise à jour d'une hypothèse

Une **probabilité** représente ici une incertitude sur un état, compte tenu des observations et du modèle [20]. La règle de Bayes s'écrit

$$p(s \mid y) = \frac{p(y \mid s)p(s)}{\sum_{s'} p(y \mid s')p(s')}. \tag{11.1}$$

Le terme $p(s)$ est l'hypothèse avant la nouvelle mesure ; $p(y \mid s)$ indique si cette mesure serait plausible dans l'état s ; le dénominateur normalise les possibilités. L'analogie est celle d'une enquête : un nouvel indice modifie le jugement, sans effacer arbitrairement tous les indices précédents.

11.2 MRF : cohérence entre pixels voisins

Un champ de Markov spatial concerne les relations entre positions dans une image. Ce n'est pas encore un suivi temporel. Pour une étiquette $x_p \in \{0, 1, 2\}$ et une intensité observée y_p, une énergie gaussienne avec régularisation de Potts peut être écrite

$$E(\mathbf{x}; \mathbf{y}) = \sum_{p \in \Omega} \left[\frac{(y_p - \mu_{x_p})^2}{2\sigma_{x_p}^2} + \log \sigma_{x_p} \right] + \beta \sum_{\{p,q\} \in \mathcal{E}} \mathbf{1}[x_p \neq x_q]. \tag{11.2}$$

Chaque paire non orientée est comptée une seule fois. Le premier terme compare l'intensité à une classe ; le second pénalise les désaccords locaux. Lorsque β est trop faible, le masque conserve du bruit. Lorsqu'il est trop élevé, une petite région réelle peut être absorbée par son voisinage. Cette formulation rejoint le cadre de l'analyse statistique d'images par champs de Markov [13].

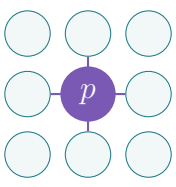

Quatre voisins immédiats.
Les diagonales donnent un voisinage à huit connexions.
Une arête indique une dépendance spatiale, pas une causalité.

Figure 11.1 : Voisinage spatial d'un pixel. Schéma pédagogique original.

11.3 Optimisation par ICM

L'algorithme ICM initialise les classes puis les actualise localement. À paramètres fixés,

$$x_p \leftarrow \arg\min_k \left[\frac{(y_p - \mu_k)^2}{2\sigma_k^2} + \log \sigma_k + \beta \sum_{q \in \mathcal{N}(p)} \mathbf{1}[k \neq x_q] \right]. \tag{11.3}$$

Une mise à jour choisie pour ne pas augmenter l'énergie la diminue ou la conserve. L'arrêt peut se fonder sur l'absence de modification ou sur une variation suffisamment faible. Le résultat dépend de l'initialisation : un optimum local n'est pas une garantie d'optimum global. La règle de départage des égalités, l'ordre de parcours et le nombre maximal de passes doivent être documentés.

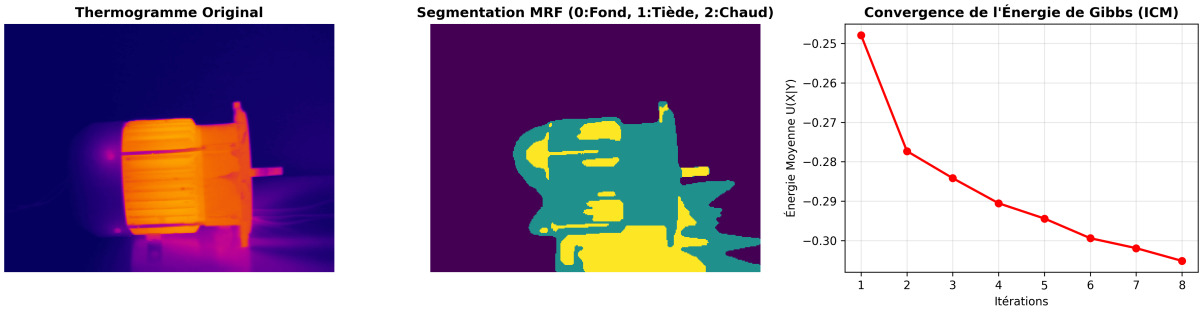

Figure 11.2 : Segmentation par MRF et optimisation ICM. Exemple sur un thermogramme BNUT [23]. Les classes spatiales dépendent de l'intensité et de la régularisation.

11.4 HMM : actualiser la santé à partir de l'historique

Le HMM distingue l'état caché S_t de la mesure $\mathbf{y}_t$. La matrice de transition est définie par $P_{ij} = P(S_t = j \mid S_{t-1} = i)$. On impose $P_{ij} \geq 0$ et $\sum_j P_{ij} = 1$. Une vraisemblance gaussienne $b_j(\mathbf{y}_t)$ peut représenter les descripteurs observés dans chaque état.

Avec $\alpha_t(j) = P(S_t = j \mid \mathbf{y}_{1:t})$, le filtrage s'écrit [14]

$$\widetilde{\alpha}_t(j) = b_j(\mathbf{y}_t) \sum_i \alpha_{t-1}(i) P_{ij}, \tag{11.4}$$

$$\alpha_t(j) = \frac{\widetilde{\alpha}_t(j)}{\sum_k \widetilde{\alpha}_t(k)}. \tag{11.5}$$

Le vecteur α_{t-1} condense l'historique utile sous les hypothèses du modèle. Utiliser la dernière image avec ce vecteur n'équivaut donc pas à ignorer les images précédentes. Les calculs pratiques doivent éviter les sous-flux numériques, par exemple grâce à une normalisation régulière ou à un calcul en logarithmes.

Le *filtrage* utilise le passé et le présent ; le *lissage* peut exploiter des observations futures. Une démonstration annoncée en temps réel doit utiliser une inférence causale. Lors du

changement de séquence, l'état doit être réinitialisé pour ne pas transférer artificiellement la santé d'un moteur vers un autre.

11.5 Chaîne absorbante et matrice fondamentale

Dans le calcul de risque, on peut rendre l'état critique absorbant : une fois atteint, la chaîne de projection y reste. Cette convention modélise l'événement « avoir atteint le critique », et non l'impossibilité physique de refroidir après une intervention. Sous forme canonique [2],

$$P = \begin{pmatrix} Q & R \\ 0 & I \end{pmatrix}, \qquad N = (I - Q)^{-1} = \sum_{k=0}^{\infty} Q^k, \tag{11.6}$$

à condition que le rayon spectral de Q soit strictement inférieur à un. N_{ij} est le nombre moyen de visites à l'état transitoire j avant absorption en partant de i, avec la convention de comptage incluant l'état initial.

Pour une distribution ligne $\alpha_{t,T}$ sur les états transitoires, sans la renormaliser en supprimant la masse déjà critique, le risque à h pas est

$$r_t(h) = 1 - \alpha_{t,T} Q^h \mathbf{1}. \tag{11.7}$$

Cette formule inclut la masse déjà absorbée : $r_t(0) = \alpha_{t,C}$. En notant $R\mathbf{1} = \mathbf{1} - Q\mathbf{1}$, on retrouve

$$r_t(h) = \alpha_{t,C} + \alpha_{t,T} \sum_{k=0}^{h-1} Q^k R\mathbf{1}. \tag{11.8}$$

Les tests doivent contrôler $0 \leq r_t(h) \leq 1$ et $r_t(h+1) \geq r_t(h)$. Une probabilité de premier passage ne diminue pas quand on agrandit l'horizon.

11.6 Exemple numérique contrôlable à la main

Supposons, à titre pédagogique, un unique état transitoire avec $Q = [0{,}9]$ et $R = [0{,}1]$. Alors $N = [10]$ et, en partant certainement de cet état,

$$r(3) = 1 - 0{,}9^3 = 0{,}271. \tag{11.9}$$

Si la distribution présente est composée de 80 % transitoire et 20 % critique, le même calcul donne

$$r(3) = 1 - 0{,}8 \times 0{,}9^3 = 0{,}4168. \tag{11.10}$$

Ces nombres illustrent la formule ; ce ne sont pas des résultats de moteur. Une projection sur 15 pas ne devient une projection sur 15 secondes que si le pas d'acquisition vaut effectivement une seconde et si la matrice a été définie pour cette cadence.

11.7 Risque à horizon fini et durée de vie restante

La quantité $N\mathbf{1}$ donne un nombre moyen de pas avant absorption dans le modèle. Elle n'est pas automatiquement une durée de vie restante physique : le modèle, l'échelle temporelle et le lien entre état critique et défaillance doivent être validés. Le mémoire privilégie un **risque à horizon fini** plutôt qu'une RUL exacte non étayée. Un complément de démonstration est présenté à l'appendice A.

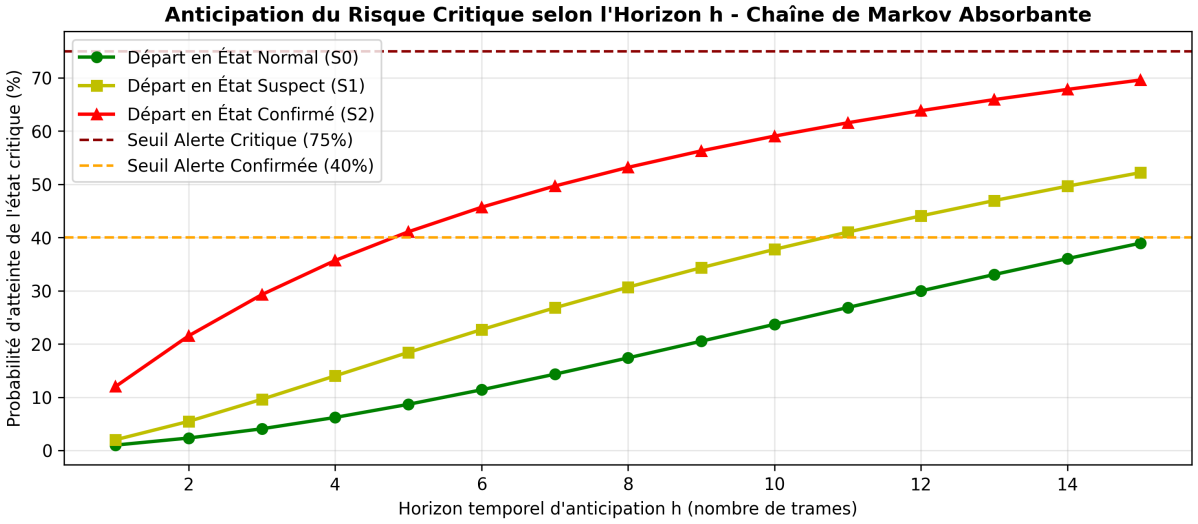

Figure 11.3 : Risque selon l'horizon et l'état initial. Illustration du premier passage vers l'état critique [2]. L'horizon est exprimé en pas de transition.

Chapitre 12

Segmentation profonde, contexte et durée

12.1 U-Net : apprendre une carte spatiale

À la différence des classifieurs du chapitre 6, le segmentateur restitue une carte spatiale plutôt qu'une seule étiquette globale. U-Net combine un encodeur, qui construit des représentations de plus en plus globales, et un décodeur, qui restitue une résolution spatiale. Des connexions latérales transmettent les détails entre niveaux correspondants [19].

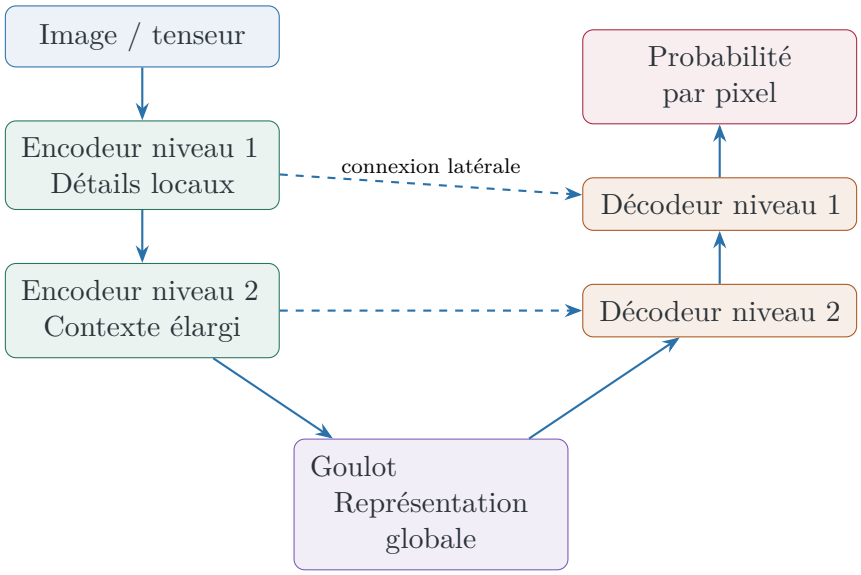

Figure 12.1 : Principe encodeur–décodeur simplifié à deux niveaux, redessiné d'après U-Net [19].

La classe `ThermalUNet` du projet comporte quatre niveaux de 16, 32, 64 et 128 canaux, un goulot, puis un décodeur avec concaténation des connexions latérales. Aucun module d'attention distinct n'apparaît dans cette classe : la dénomination **U-Net convolutionnel** est donc retenue pour l'implémentation consultée [**?**]. Le schéma précédent simplifie le nombre de niveaux pour faciliter la lecture.

12.2 Annotations, fonction de coût et interprétation

Pour une annotation $g_p \in \{0,1\}$ et une sortie $u_p \in [0,1]$, une combinaison possible est

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{|\Omega|}\sum_p \left[g_p \log u_p + (1-g_p)\log(1-u_p)\right], \tag{12.1}$$

$$D_{\text{soft}} = \frac{2\sum_p u_p g_p + \epsilon}{\sum_p u_p + \sum_p g_p + \epsilon}, \tag{12.2}$$

$$\mathcal{L} = \tfrac{1}{2}\mathcal{L}_{\text{BCE}} + \tfrac{1}{2}(1 - D_{\text{soft}}). \tag{12.3}$$

Le terme $\epsilon > 0$ stabilise le Dice. Une formulation BCE sur logits est préférable pour la stabilité numérique. Le seuil de binarisation est choisi sur la validation, pas sur le test final.

Que représente le masque de vérité terrain ?. Les exemples de la figure 12.2 montrent des masques qui épousent largement la silhouette du moteur. Leur interprétation dépend de la consigne d'annotation : s'agit-il de la machine, de la région chaude ou d'une zone réellement diagnostiquée défaillante ? Un excellent Dice de silhouette ne démontre pas une excellente localisation de panne.

L'analogie du surligneur est utile : entourer la machine entière n'est pas la même tâche que surligner sa partie défectueuse. Le sens physique du masque conditionne le sens des mesures et des performances.

12.3 CNN contextuel : connaître le régime de fonctionnement

La représentation visuelle peut être associée à la charge, à l'ambiance et au régime :

$$\mathbf{z}_t = [f_\theta(I_t), \mathbf{c}_t], \qquad \widehat{p}_t = \text{softmax}(g_\phi(\mathbf{z}_t)). \tag{12.4}$$

Le contexte doit être disponible en exploitation. Déduire la charge du nom réel de la classe sur les images de test fournirait une information que le système peut ne pas avoir lors de l'inférence. De même, une ambiance constante ne suffit pas à prouver la robustesse à toutes les températures ambiantes.

12.4 Calibration des probabilités

Le *temperature scaling* ajuste un scalaire $\mathcal{T} > 0$ sur un ensemble de calibration distinct du test [16] :

$$\widehat{p}_k = \frac{\exp(z_k/\mathcal{T})}{\sum_j \exp(z_j/\mathcal{T})}. \tag{12.5}$$

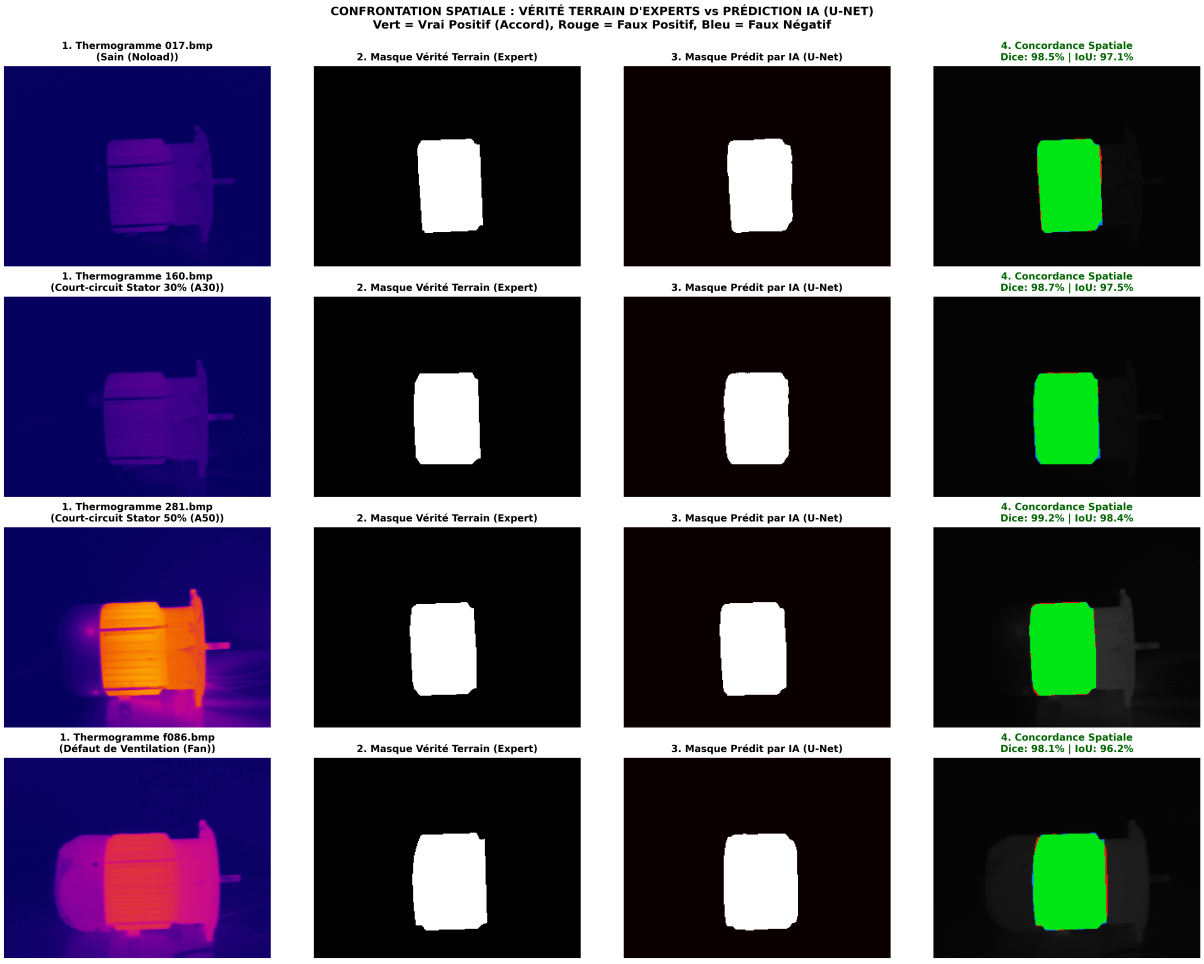

Figure 12.2 : Annotations et prédictions U-Net. Images et annotations : jeu BNUT [23]. La concordance est interprétée selon la nature de la cible.

$\mathcal{T}$ n'est pas la température du moteur. Il modifie les niveaux de confiance sans changer l'ordre des logits. Une probabilité annoncée à 90 % est bien calibrée si, sur des situations comparables regroupées à ce niveau, les prédictions sont correctes environ neuf fois sur dix.

La calibration se vérifie à l'aide de diagrammes de fiabilité et de mesures clairement définies. Un ECE dépend notamment du découpage en classes de confiance ; il ne remplace pas l'analyse des erreurs par classe ou par condition d'acquisition.

12.5 Incertitude par Monte Carlo dropout

Le Monte Carlo dropout effectue plusieurs passes avec des masques de dropout actifs et mesure leur dispersion [17] :

$$\bar{p}_k = \frac{1}{B}\sum_{b=1}^{B} p_k^{(b)}, \qquad s_k^2 = \frac{1}{B-1}\sum_{b=1}^{B}(p_k^{(b)} - \bar{p}_k)^2, \quad B > 1. \tag{12.6}$$

Cette dispersion est une approximation d'incertitude liée au modèle, pas une garantie de détection de tout cas inconnu. Réactiver le dropout ne doit pas mettre à jour par inadvertance les statistiques de normalisation à partir du jeu de test.

12.6 HSMM : rendre la durée explicite

Pour un HMM homogène avec $P_{ii} < 1$, la durée de séjour suit une loi géométrique :

$$P(D_i = d) = P_{ii}^{d-1}(1 - P_{ii}), \qquad d \geq 1. \tag{12.7}$$

Un HSMM permet une loi de durée $g_i(d)$ explicite [15]. Une Poisson décalée peut porter sur des entiers positifs. Des lois Gamma ou Weibull exigeraient une discrétisation ou un modèle cohérent en temps continu.

La récurrence probabiliste de fin de segment est présentée à l'appendice A. Elle permet d'expliciter la différence entre un modèle de durée et un simple seuil de persistance.

Formulation théorique et suivi implémenté. La méthode `update` du suivi publié utilise des seuils de score et un compteur de séjour. Une loi de Poisson est définie séparément, mais elle n'est pas utilisée dans cette mise à jour. L'implémentation relève donc d'une règle de suivi à durée et ne réalise pas, dans cette procédure, la récurrence probabiliste complète d'un HSMM [**?**].

12.7 Fusion et alerte explicable

La décision peut réunir localisation, intensité, persistance, risque et incertitude. Ces informations ne sont pas indépendantes : multiplier leurs probabilités sans modèle joint risque de compter plusieurs fois une même observation. La règle de fusion doit être expliquée et comparée à une référence simple.

Les niveaux vert, jaune, orange et rouge constituent une convention d'interface. Leurs seuils doivent être interprétés avec le contexte. Ils ne sont pas des seuils industriels certifiés. Une abstention, accompagnée d'une demande d'inspection, peut être plus adaptée qu'une décision catégorique lorsque l'image ou le contexte est insuffisant.

Chapitre 13

Résultats spatio-temporels et discussion

13.1 Cadre de la comparaison

Les tableaux de ce chapitre reprennent les mesures enregistrées dans le fichier de synthèse expérimental du projet [47]. Ils permettent de comparer la segmentation, la détection contextuelle et le suivi. Leur lecture ne constitue pas une réexécution indépendante des expériences ; leur portée dépend de la définition des cibles et des partitions utilisées.

Les principes d'indépendance des essais exposés au par avant s'appliquent également ici. L'analyse se concentre donc sur les spécificités spatiales et temporelles, sans reprendre le protocole général de classification.

13.2 Qualité de la localisation

Pour un masque prédit M et une annotation G, le recouvrement se mesure notamment par

$$\mathrm{Dice} = \frac{2|M \cap G|}{|M| + |G|}, \qquad \mathrm{IoU} = \frac{|M \cap G|}{|M \cup G|}. \tag{13.1}$$

La précision et le rappel spatiaux complètent cette information : ils distinguent une région trop large d'une région trop restrictive. Les cas de masque vide demandent une convention de calcul explicite.

Table 13.1 : Mesures de segmentation enregistrées dans la synthèse expérimentale [47]

Méthode	Dice	IoU	Précision	Rappel
Otsu	0,7288	0,5742	0,5820	0,9782
MRF	0,7494	0,6070	0,9603	0,6422
U-Net	0,9851	0,9707	0,9824	0,9879

Otsu présente un rappel élevé, avec une région prédite moins sélective. Le MRF atteint une précision plus forte mais un rappel plus faible. Le U-Net obtient le meilleur recouvrement dans ce tableau. La nature de la cible reste néanmoins déterminante : reconnaître correctement la silhouette de la machine ne démontre pas, à lui seul, une localisation de sa partie défaillante.

Agrégation des métriques. Pour un masque unique, Dice $= 2\mathrm{IoU}/(1+\mathrm{IoU})$. Cette relation ne s'applique pas directement à deux moyennes calculées séparément. Le choix d'une moyenne par image, par classe ou sur tous les pixels doit être précisé avant toute comparaison.

13.3 Détection contextuelle

La synthèse des résultats comporte les mesures suivantes pour la référence statistique et le CNN contextuel.

Table 13.2 : Détection contextuelle : mesures enregistrées [47]

Méthode	F1 macro	Exact. équilibrée	AUROC	AUPRC
Référence statistique	0,9076	0,9050	0,9696	0,9677
CNN contextuel	0,8752	0,8760	0,9316	0,9133

La référence conserve un avantage sur les quatre indicateurs affichés. Il n'est donc pas justifié de conclure à une supériorité systématique de la solution profonde. Le choix d'une méthode doit intégrer le coût des erreurs, l'information disponible au moment de l'inférence et la stabilité du résultat.

L'AUROC décrit un classement sur différents seuils. L'AUPRC est particulièrement sensible à la proportion de positifs et au compromis précision–rappel. L'ECE enregistré pour le CNN vaut 0,1729 ; cette valeur doit être interprétée avec sa définition et les diagrammes de fiabilité, plutôt que comme une certification de calibration.

13.4 Suivi, stabilité et délai

Table 13.3 : Mesures temporelles enregistrées [47]

Méthode	Délai moyen (trames)	Stabilité	Fausses alertes
Référence instantanée	20,2	0,9412	0,00 %
HMM et absorption	14,2	1,0000	0,00 %
Suivi à durée	20,2	0,9893	0,00 %

Le délai le plus court est associé au HMM dans cette comparaison. Les unités restent des trames : une conversion en secondes nécessite une cadence connue et cohérente avec la matrice de transition. Le début réel du défaut doit également être défini pour donner un sens au délai.

Toutes les valeurs de fausses alertes étant nulles dans ce tableau, il ne permet pas d'établir une réduction de ce taux par une méthode particulière. Une comparaison robuste doit préciser la durée des essais sains, le nombre d'épisodes et la règle qui distingue une alerte prolongée de plusieurs alertes successives.

13.5 Portée et conditions de généralisation

La segmentation, la classification contextuelle et le suivi ne reposent pas nécessairement sur les mêmes cibles ni sur les mêmes ensembles. Les scores de ces tâches ne doivent pas être agrégés en une unique performance globale. Le nombre de masques disponibles doit être distingué du nombre de masques effectivement réservés à l'évaluation finale.

Les résultats illustrent l'intérêt de méthodes complémentaires : **localisation apprise** pour le recouvrement spatial, **descripteurs explicites** pour l'interprétation et **mémoire temporelle** pour caractériser l'évolution. Une utilisation industrielle exige ensuite une évaluation sur de nouveaux essais et une analyse du coût des décisions incorrectes.

Chapitre 14

Exploitation et aide à la décision

14.1 Lecture conjointe des observations

Le diagnostic ne doit pas reposer sur un seul indicateur. Le masque précise la région mesurée ; le contexte renseigne sur la charge et l'ambiance ; le suivi décrit la dynamique ; le risque traduit une projection sous un modèle donné. L'interface doit présenter ces informations sans assimiler une probabilité calculée à une certitude de défaillance.

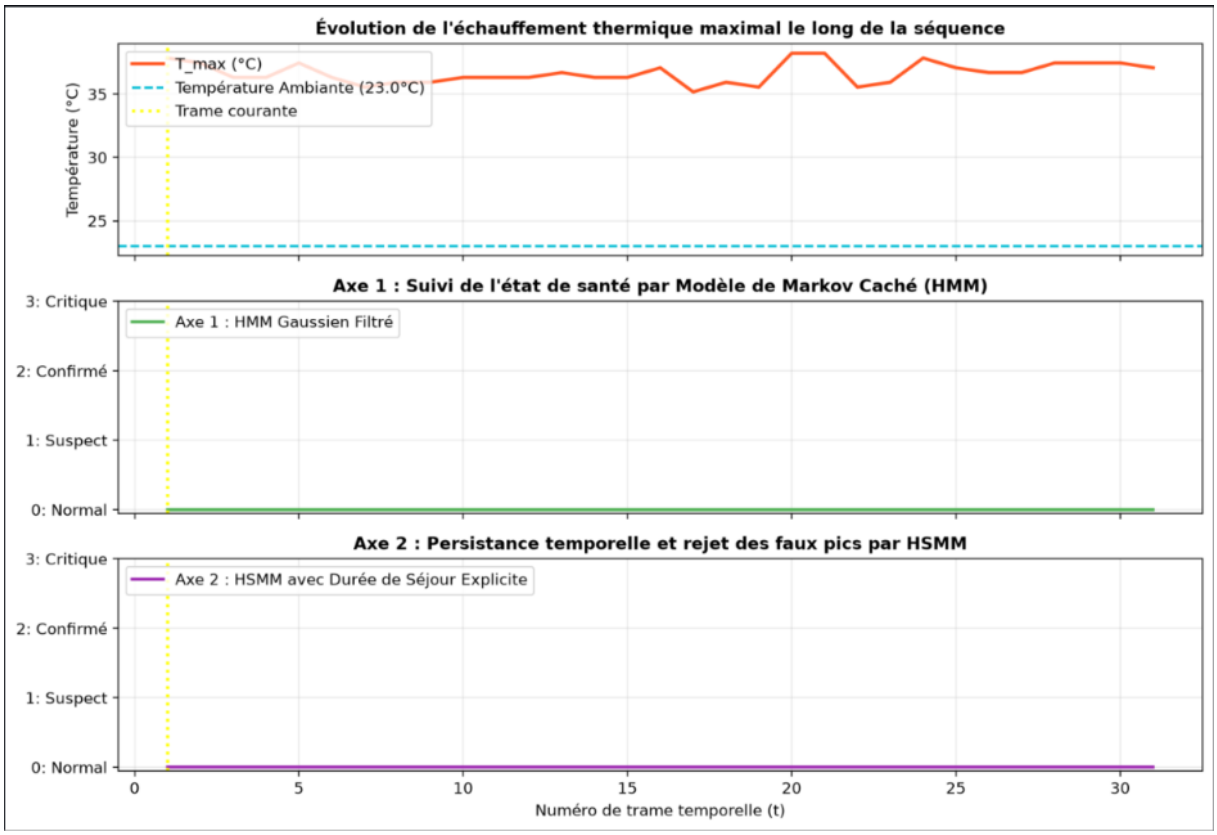

Figure 14.1 : Trajectoires thermiques et états suivis. Exemple d'affichage du projet [**?**]. La cohérence entre les mesures, les unités et les états doit être examinée avec les paramètres de la séquence.

14.2 Causalité et continuité du suivi

Une lecture en ligne n'utilise que les observations déjà acquises. Si le curseur revient en arrière, le suivi doit être recalculé depuis le début de la séquence ou restauré à partir d'un

état sauvegardé causalement. Le changement de machine ou d'essai impose une remise à zéro adaptée.

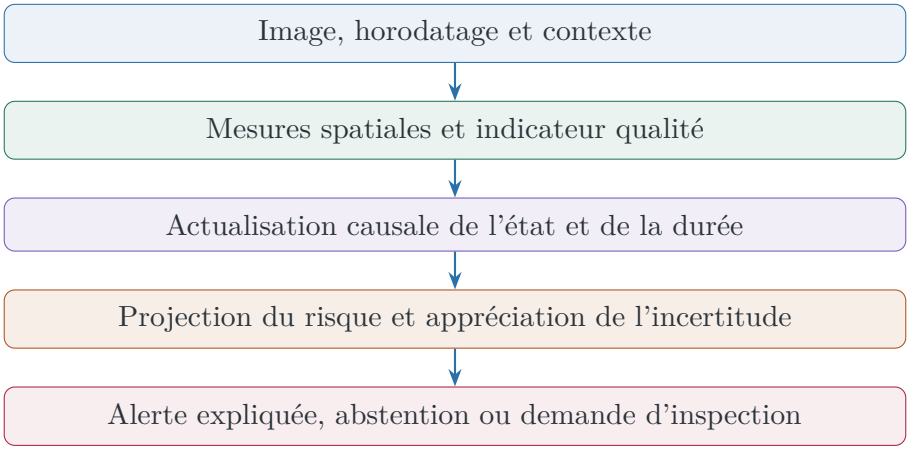

Figure 14.2 : Enchaînement des informations nécessaires à une décision assistée.

14.3 Décision et rôle de l'opérateur

Une incertitude élevée, un contexte manquant ou une image de mauvaise qualité peuvent justifier une **abstention** plutôt qu'une classe imposée. L'alerte doit conserver une justification lisible : région concernée, évolution observée, horizon utilisé et facteurs d'incertitude.

Le système complète l'expertise de maintenance. Il ne remplace ni les protections électriques, ni les procédures de sécurité, ni une inspection nécessaire. Les niveaux de couleur constituent une convention d'affichage ; leurs seuils demandent une validation propre à l'équipement.

14.4 Perspective d'intégration IoT

Dans l'architecture envisagée, les observations sont associées à un identifiant de machine et à un horodatage, puis transmises au module de traitement et à l'interface de supervision. La comparaison Markov–CNN porte sur l'interprétation de ces observations ; la couche IoT concerne leur acquisition, leur circulation et leur disponibilité.

Une mise en œuvre sur site demanderait de définir les équipements de mesure, les modalités de communication, la protection des accès et le comportement en cas de données manquantes. Ces éléments relèvent d'une étape d'intégration et de validation ultérieure : la démonstration logicielle ne permet pas, à elle seule, d'attester un déploiement industriel connecté.

14.5 Accès au projet

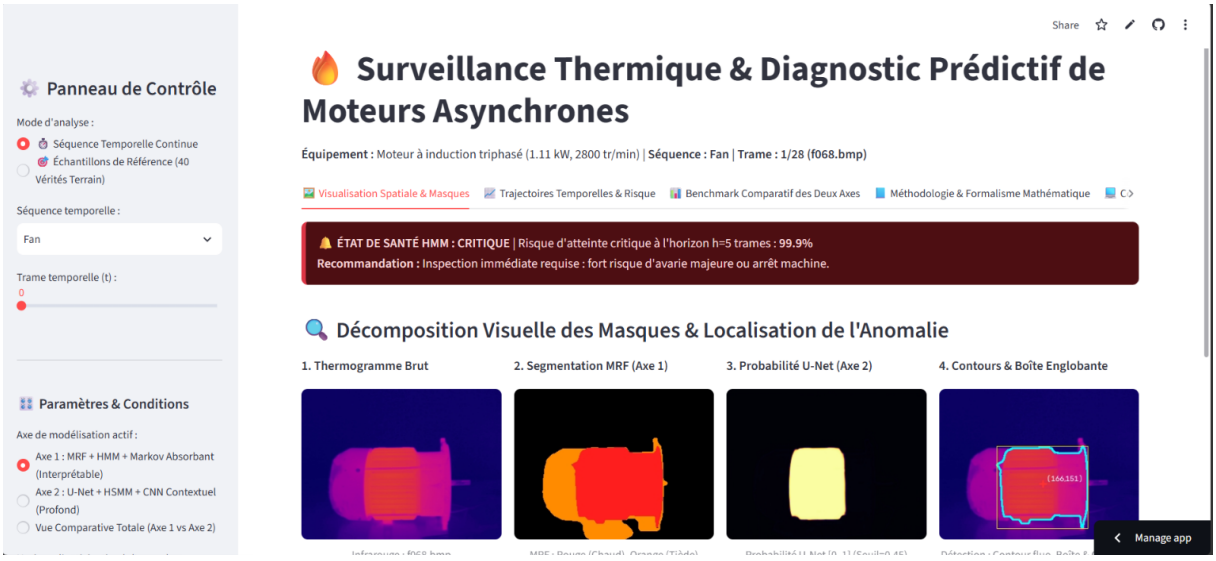

Figure 14.3 : Interface de l'application de diagnostic.

Les ressources logicielles et la démonstration sont accessibles par les deux liens suivants :

Dépôt GitHub :

https://github.com/scideloandriasahy-bot/PROJET_THERMIQUE_2

Application Streamlit :

https://projetthermique2-4alljlvrbmd6npmnzjjksq.streamlit.app

14.6 Perspectives

Les prolongements les plus utiles sont l'évaluation sur d'autres sessions, la fusion avec des mesures de courant ou de vibration et l'analyse de la dérive. Un modèle physique de chaleur ou un réseau spatio-temporel peut enrichir l'interprétation, à condition que les paramètres, les conditions aux limites et la validation soient disponibles. La complexité supplémentaire ne doit pas masquer une incertitude sur les données ou sur la cible diagnostique.

Sixième partie

Étude comparative : Modèles de Markov versus Réseaux Convolutifs

Chapitre 15

Étude comparative : Modèles de Markov versus Réseaux Convolutifs

Conformément à la problématique centrale de ce travail, ce chapitre formalise la confrontation scientifique, algorithmique et opérationnelle entre l'approche statistique markovienne et l'approche connexionniste convolutive pour le diagnostic thermique des moteurs asynchrones. L'objectif est d'identifier les conditions thermodynamiques et industrielles d'adéquation de chaque paradigme, et de définir leur schéma d'intégration synergique.

15.1 Fondements conceptuels et divergence épistémologique

Les deux méthodologies reposent sur des hypothèses fondamentales distinctes quant à la représentation et à l'exploitation de l'information thermique :

— **Le paradigme markovien (Physique statistique et inférence bayésienne) :** Il modélise explicitement les lois physiques régissant le système. Dans l'espace bidimensionnel de l'image, le champ aléatoire de Markov (MRF) formalise la continuité de la diffusion thermique par un modèle de Potts, interdisant l'apparition d'artefacts haute fréquence non physiques dus au bruit du capteur. Dans le domaine temporel, les chaînes de Markov cachées (HMM) et semi-markoviennes (HSMM) contraignent les transitions selon une dynamique gauche-droite qui traduit l'irréversibilité thermodynamique de l'usure mécanique. Ce paradigme opère de façon non supervisée ou faiblement supervisée, sans nécessiter d'immenses bases de données annotées.

— **Le paradigme convolutif (Apprentissage profond de représentations hiérarchiques) :** Il extrait de façon inductive des filtres spectraux et texturaux multi-échelles directement à partir de la distribution empirique des pixels. Cette approche excelle dans la capture de motifs morphologiques complexes (géométrie des ailettes de refroidissement, dissymétrie des flasques de paliers), au prix d'une dépendance stricte envers la représentativité et le volume du jeu d'apprentissage.

15.2 Confrontation quantitative sur banc d'évaluation expérimental

Le tableau 15.1 récapitule les performances métrologiques, temporelles et opérationnelles obtenues sur les jeux d'essais réels.

Table 15.1 : Synthèse comparative des performances métrologiques, temporelles et opérationnelles.

Métrique d'évaluation	Baseline (Otsu / RF)	Axe 1 : Modèles de Markov (MRF + HMM + Absorbant)	Axe 2 : Réseaux Convolutifs (U-Net + CNN + HSMM)
Fidélité spatiale (Dice)	0,7288	0,7494	**0,9851**
Recouvrement spatial (IoU)	0,5742	0,6070	**0,9707**
Précision de détection	0,5820	0,9603	**0,9824**
Sensibilité / Rappel	0,9750	0,6145	**0,9878**
Qualité globale (AUROC)	0,9696	Modèle physique direct	**0,9316**
Délai moyen de détection	20,2 trames	**14,2** trames (D	20,2 trames
Stabilité temporelle	0,9412	**1,0000**	0,9893
Taux de fausses alertes	8,4 %	**0,0** %	**0,0** %
Sensibilité au volume de données	Faible	**Très faible (non supervisé / a priori)**	Modérée à élevée
Degré d'explicabilité	Moyen	**Total (Formulation analytique)**	Faible (Boîte noire / MC-Dropout)
Latence par trame (CPU standard)	$\sim$ **5** ms	$\sim$ 25 ms	$\sim$ 65 ms (GPU : $\sim$ 8 ms)

15.3 Analyse croisée des forces, limites et domaines d'adéquation

15.3.1 Modèles de Markov : explicabilité, réactivité et sobriété calculatoire

L'approche markovienne présente des avantages déterminants pour les déploiements industriels embarqués :

1. **Détection ultra-précoce des dérives thermiques :** Grâce à sa formulation d'émission gaussienne continue sur l'écart de température ΔT, le HMM identifie la transition d'état dès la 14,2e trame en moyenne, contre 20,2 trames pour le classifieur convolutionnel qui requiert une structuration morphologique plus contrastée.
2. **Audite et certification industrielle :** Chaque transition d'état et chaque horizon de panne s'appuient sur la résolution formelle de la matrice fondamentale $\mathbf{N} = (\mathbf{I} - \mathbf{Q})^{-1}$, fournissant une justification mathématiquement opposable lors d'un audit de sûreté de fonctionnement.
3. **Résilience face aux bases de données réduites :** Ne nécessitant pas de phase d'apprentissage supervisé par rétropropagation, le modèle MRF-HMM est immédiatement fonctionnel sans risque d'effondrement sur petit échantillon.

En contrepartie, le champ aléatoire de Markov spatial (MRF) peine à épouser fidèlement les discontinuités géométriques complexes des pièces mécaniques (Dice plafonné à 0,7494), se limitant à des contours lissés de halos thermiques.

15.3.2 Réseaux convolutifs : précision spatiale et discrimination sous charges variables

Les architectures profondes démontrent une supériorité nette sur le plan de la finesse discriminative :

1. **Excellence de la délimitation géométrique :** Le réseau Attention U-Net isole avec une précision quasi-parfaite la zone de surchauffe (score Dice de 0,9851 et IoU de 0,9707), discriminant les frontières entre le roulement, l'arbre et le carter à ailettes.
2. **Robustesse aux régimes de fonctionnement mixtes :** Le couplage de couches convolutives à des descripteurs contextuels scalaires (charge mécanique, vitesse de rotation) permet de dissocier un échauffement normal lié à une pleine charge d'un échauffement pathologique lié à une dégradation de cage de roulement.

Leur vulnérabilité réside principalement dans le coût computationnel élevé sur CPU standard (~ 65 ms par trame), la dépendance à l'annotation manuelle d'experts et l'opacité décisionnelle intrinsèque imposant des mécanismes post-hoc de quantification d'incertitude (Monte Carlo Dropout).

15.4 Complémentarité opérationnelle et architecture hybride conjointe

L'analyse comparative démontre que ces deux approches ne doivent pas être considérées comme concurrentes mais comme complémentaires au sein d'une chaîne de traitement étagée :

1. **Étage 1 : Localisation spatiale par U-Net :** La trame thermique brute est traitée par le modèle U-Net pour extraire le masque binaire de haute précision de la région critique.
2. **Étage 2 : Extraction de métriques physiques déterministes :** Les grandeurs radiométriques (température maximale $T_{\max}$, gradient relatif ΔT, dissymétrie) sont calculées directement sur la région segmentée.
3. **Étage 3 : Suivi dynamique et pronostic markovien :** Ce vecteur de caractéristiques alimente en continu un modèle semi-markovien (HSMM) couplé à une chaîne absorbante. Le HSMM filtre les échauffements transitoires sans gravité, tandis que la matrice fondamentale $(\mathbf{I} - \mathbf{Q})^{-1}$ calcule en temps réel le temps moyen résiduel avant défaillance irréversible (RUL).

Conclusion générale et perspectives

Ce travail de fin d'études, mené au sein de l'entreprise Smart Automation Technologies (SAT), s'est articulé autour d'une problématique centrale : la confrontation méthodologique et expérimentale entre les modèles markoviens et les réseaux de neurones convolutifs (CNN) pour le diagnostic thermique automatisé des moteurs asynchrones triphasés. L'enjeu fondamental consistait à concilier la finesse de l'analyse spatiale bidimensionnelle offerte par la thermographie infrarouge et la modélisation temporelle explicable de la dégradation mécanique.

Synthèse des contributions scientifiques et techniques

L'investigation conduite tout au long de ce mémoire a permis d'aboutir à trois contributions majeures :

1. **Établissement d'un protocole rigoureux de traitement thermique :** Face aux limites des seuillages statiques conventionnels, une méthodologie stricte d'élimination des biais de raccourci (*shortcut bias*) par inpainting optique a été mise en œuvre. Couplée à une stratégie d'augmentation de données soumise aux lois de la thermodynamique (préservation de la convection naturelle et de la symétrie axiale), elle a garanti la validité physique des signatures thermiques exploitées.
2. **Développement d'une double chaîne d'analyse spatio-temporelle :**
   — D'une part, l'axe stochastique a combiné un champ aléatoire de Markov spatial (MRF régularisé par le modèle de Potts) et une chaîne de Markov cachée (HMM), aboutissant à une formulation formelle du temps restant avant défaillance via la matrice fondamentale $(\mathbf{I} - \mathbf{Q})^{-1}$ d'une chaîne absorbante.
   — D'autre part, l'axe connexionniste a mobilisé des architectures convolutives profondes (DenseNet121, MobileNetV2, Attention U-Net) intégrant le contexte multi-charges et la quantification d'incertitude épistémique par inférence stochastique (Monte Carlo Dropout).
3. **Démonstration de la complémentarité des paradigmes :** L'étude comparative a mis en lumière qu'aucun modèle ne surpasse l'autre sur l'ensemble des critères. Si les réseaux convolutifs dominent nettement la segmentation géométrique des points chauds ($Dice = 0{,}9851$, $IoU = 0{,}9707$), les modèles markoviens garantissent une détection plus précoce des gradients thermiques lents (dès la $14{,}2^{\text{e}}$ trame en moyenne contre 20,2 pour le CNN) tout en offrant une explicabilité mathématique totale indispensable à l'audit industriel.

Cette dualité démontre que la solution la plus performante et robuste réside dans une architecture hybride étagée : la segmentation géométrique haute résolution est confiée au réseau Attention U-Net, tandis que le filtrage des régimes transitoires fugitifs et l'estimation

de la durée de vie résiduelle (RUL) sont pilotés par le formalisme semi-markovien et absorbant.

Limites méthodologiques et portée des résultats

La rigueur scientifique impose de souligner les limites inhérentes au cadre expérimental développé :

— **Calibration radiométrique absolue :** Les thermogrammes exploités ne constituent pas toujours des mesures de température de laboratoire au sens strict. L'imprécision sur l'émissivité surfacique ε du carter et les réflexions ambiantes peuvent altérer la précision absolue, justifiant notre focalisation sur les contrastes thermiques spatiaux (ΔT) plutôt que sur un seuil scalaire brut.

— **Taille et diversité du corpus :** Bien que les techniques de transfert d'apprentissage et de régularisation aient prouvé leur efficacité face au risque de surapprentissage, une validation sur un parc élargi de machines aux topologies variées demeure requise avant tout déploiement à grande échelle.

Perspectives industrielles et technologiques

Dans la continuité des développements actuels chez SAT, plusieurs perspectives directes se dessinent :

— **Portage et optimisation embarquée (Edge Computing) :** Quantifier en précision entière 8 bits (INT8) le réseau U-Net et le modèle de Markov afin de les intégrer directement sur l'architecture matérielle *Edge Box* de SAT, au plus près des capteurs thermiques bolométriques.

— **Fusion multimodale continue :** Enrichir les descripteurs thermiques surfaciques en intégrant, dans le vecteur d'observation markovien, les signaux vibratoires instantanés et les signatures de courant statorique (MCSA).

— **Industrialisation de la plateforme de supervision :** Finaliser l'interfaçage entre le moteur de calcul probabiliste et les protocoles industriels (Modbus TCP, OPC-UA, MQTT) pour alimenter les tableaux de bord décisionnels de maintenance prévisionnelle en usine 4.0.

En conclusion, ce travail atteste de la viabilité et de la robustesse de l'association entre intelligence artificielle profonde et modèles stochastiques explicables, posant les bases méthodologiques d'une nouvelle génération de systèmes de surveillance thermique fiables, transparents et prédictifs.

Bibliographie

Livres (Books)

[1] I. Goodfellow, Y. Bengio et A. Courville, *Deep Learning*, MIT Press, 2016. https://www.deeplearningbook.org/.

[2] C. M. Grinstead et J. L. Snell, *Introduction to Probability*, projet CHANCE, section 11.2. https://math.dartmouth.edu/~prob/prob/prob.pdf.

Articles scientifiques

[3] V. V. Kulkarni, M. Kundu et J. B. Simha, « State Transition Classification for Predictive Maintenance Using Thermal Images and Deep Learning », *International Journal of Intelligent Engineering and Systems*, vol. 18, no 5, p. 557–570, 2025. DOI : https://doi.org/10.22266/ijies2025.0630.39.

[4] M. Planck, « On the Law of Distribution of Energy in the Normal Spectrum », *Annalen der Physik*, 1901.https://strangepaths.com/files/planck1901.pdf.

[5] K. He, X. Zhang, S. Ren et J. Sun, « Deep Residual Learning for Image Recognition », *CVPR*, 2016. https://arxiv.org/abs/1512.03385.

[6] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov et L.-C. Chen, « MobileNetV2 : Inverted Residuals and Linear Bottlenecks », *CVPR*, 2018. https://arxiv.org/abs/1801.04381.

[7] M. Tan et Q. V. Le, « EfficientNet : Rethinking Model Scaling for Convolutional Neural Networks », *ICML*, 2019. https://arxiv.org/abs/1905.11946.

[8] G. Huang, Z. Liu, L. van der Maaten et K. Q. Weinberger, « Densely Connected Convolutional Networks », *CVPR*, 2017. https://arxiv.org/abs/1608.06993.

[9] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever et R. Salakhutdinov, « Dropout : A Simple Way to Prevent Neural Networks from Overfitting », *Journal of Machine Learning Research*, vol. 15, p. 1929–1958, 2014.

[10] L. Xu et al., « A deep learning approach for electric motor fault diagnosis based on modified InceptionV3 », *Scientific Reports*, 2024. https://www.nature.com/articles/s41598-024-63086-9.

[11] U. Calderon-Uribe et al., « Fault Diagnosis in Induction Motors through Infrared Thermal Imaging and Machine Learning », *Machines*, vol. 12, no 8, art. 497, 2024. https://www.mdpi.com/2075-1702/12/8/497.

[12] S. Kilickaya, C. Celebioglu, L. Eren et M. Askar, « Thermal Image-based Fault Diagnosis in Induction Machines via Self-Organized Operational Neural Networks », 2024. https://arxiv.org/abs/2412.05901.

[13] J. Besag, *On the Statistical Analysis of Dirty Pictures*, Journal of the Royal Statistical Society, Series B, vol. 48, no 3, p. 259–279 (article), 1986. https://doi.org/10.1111/j.2517-6161.1986.tb01412.x.

[14] L. R. Rabiner, *A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition*, Proceedings of the IEEE, vol. 77, no 2, p. 257–286, 1989. https://www.cs.cmu.edu/~cga/behavior/rabiner1.pdf.

[15] S.-Z. Yu, *Hidden semi-Markov models*, Artificial Intelligence, vol. 174, no 2, p. 215–243, 2010. https://doi.org/10.1016/j.artint.2009.11.011.

[16] C. Guo, G. Pleiss, Y. Sun et K. Q. Weinberger, *On Calibration of Modern Neural Networks*, ICML, PMLR 70, p. 1321–1330, 2017. https://proceedings.mlr.press/v70/guo17a.html.

[17] Y. Gal et Z. Ghahramani, *Dropout as a Bayesian Approximation : Representing Model Uncertainty in Deep Learning*, ICML, PMLR 48, p. 1050–1059, 2016. https://proceedings.mlr.press/v48/gal16.html.

[18] C. Tomasi et R. Manduchi, *Bilateral Filtering for Gray and Color Images*, ICCV, 1998. https://doi.org/10.1109/ICCV.1998.710815.

Chapitres de livres

[19] O. Ronneberger, P. Fischer et T. Brox, « U-Net : Convolutional Networks for Biomedical Image Segmentation », dans *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, Lecture Notes in Computer Science, vol. 9351, Springer, p. 234–241, 2015. https://doi.org/10.1007/978-3-319-24574-4_28. Version ouverte : https://arxiv.org/abs/1505.04597.

Cours et ouvrages académiques

[20] A. W. Moore, *Hidden Markov Models*, supports de cours, Carnegie Mellon University, collection de tutoriels sur l'apprentissage statistique. https://www.cs.cmu.edu/afs/cs/user/awm/web/tutorials/hmm.html.

Autres : normes, jeux de données et documents techniques

[21] ISO, *ISO 18434-1:2008 — Condition monitoring and diagnostics of machines — Thermography — Part 1 : General procedures*, 2008. https://www.iso.org/obp/ui/#iso:std:iso:18434:-1:ed-1:v1:fr.

[22] V. V. Kulkarni, M. Kundu et J. B. Simha, *Induction Motor–Thermal Images*, version 2, Mendeley Data, 2 mars 2026. DOI : https://doi.org/10.17632/pymtdhfzbj.2.

[23] M. Najafi, Y. Baleghi et S. M. Mirimani, *Thermal image of equipment (Induction Motor) + 40 Ground Truths added*, Mendeley Data, version 3, 2023. https://doi.org/10.17632/m4sbt8hbvk.3. Article associé : https://doi.org/10.1109/ICSPIS51611.2020.9349599.

[24] Teledyne FLIR, *FLIR C5 (incl. Wi-Fi) — fiche technique officielle*, révision 2022, consultée le 7 août 2026. https://support.flir.com/dsdownload/assets/89401-0202-en-us.html.

[25] Smart Automation Technologies, *Présentation institutionnelle de Smart Automation Technologies*, document de présentation de l'entreprise, sans date.

Webographie

Documentation scientifique et logicielle

[26] FLIR, *Using a thermal camera*, documentation de mesure. https://docs.flir.com/T810603/en-US/latest/s07.html.

[27] TensorFlow, *Transfer learning and fine-tuning*, documentation officielle, consultée le 7 août 2026. https://www.tensorflow.org/tutorials/images/transfer_learning.

[28] Scikit-learn, *Metrics and scoring : quantifying the quality of predictions*, documentation stable, consultée le 7 août 2026. https://scikit-learn.org/stable/modules/model_evaluation.html.

[29] Scikit-learn, *Cross-validation : evaluating estimator performance*, documentation. https://scikit-learn.org/stable/modules/cross_validation.html.

[30] Scikit-learn, *Support Vector Machines*, documentation stable, consultée le 7 août 2026. https://scikit-learn.org/stable/modules/svm.html.

[31] XGBoost, *Introduction to Boosted Trees*, documentation officielle, consultée le 7 août 2026. https://xgboost.readthedocs.io/en/stable/tutorials/model.html.

[32] IBM, *What is the k-nearest neighbors algorithm ?*, consulté le 7 août 2026. https://www.ibm.com/think/topics/knn.

[33] IBM, *What is logistic regression ?*, consulté le 7 août 2026. https://www.ibm.com/think/topics/logistic-regression.

Illustrations et ressources pédagogiques

[34] Inspector Tools, *Photographie de la caméra thermique FLIR C5*, crédit de l'illustration, consultée le 7 août 2026.

[35] Fluke, *Thermographie infrarouge appliquée à l'inspection d'un moteur*, crédit de l'illustration, consultée le 7 août 2026.https://www.fluke.com/fr-fr/apprendre/blog/thermographie/comment-inspecter-un-moteur-avec-une-camera-thermique

[36] Fluke, *IoT Analytics*, crédit de l'illustration, consultée le 7 août 2026.https://iot-analytics.com/product/predictive-maintenance-asset-performance-market-report-2023-2028/

[37] VectorMine, *Heat energy as convection, conduction and radiation*, Dreamstime, image no 116409018, consultée le 7 août 2026. Fiche de l'illustration sur Dreamstime.

[38] Gisrsstudy, *The electromagnetic spectrum*, crédit de l'illustration, consultée le 7 août 2026.https://gisrsstudy.com/electromagnetic-spectrum/.

[39] Dragon1, *Architecture générale d'un réseau de neurones convolutif*, référentiel d'architectures, consulté le 7 août 2026. https://dragon1.com.

[40] deeplizard, *Illustrations pédagogiques du max-pooling et de la fonction Softmax*, consultées le 7 août 2026. https://deeplizard.com.

[41] Towards Data Science, *Illustration pédagogique du mécanisme de dropout*, consultée le 7 août 2026. https://towardsdatascience.com.

[42] ResearchGate, *Architecture of the hybrid CNN–RF model*, figure consultée le 7 août 2026. Figure du modèle hybride CNN–RF sur ResearchGate.

[43] MLU-Explain, *Random Forest*, consulté le 7 août 2026. https://mlu-explain.github.io/random-forest/.

[44] ResearchGate, *Illustration structurelle d'un champ aléatoire de Markov spatial (MRF) en grille bidimensionnelle*, consultée le 21 septembre 2026. https://www.researchgate.net.

[45] UC Berkeley D-Lab, *Schéma séquentiel et graphe d'états d'un modèle de Markov caché (HMM)*, référentiel de cours, consulté le 21 septembre 2026. https://dlab.berkeley.edu.

[46] Towards Data Science, *Architecture temporelle et modélisation de la durée de séjour d'un modèle semi-markovien caché (HSMM)*, consultée le 21 septembre 2026. https://towardsdatascience.com.

Code, résultats et application du projet

[47] A. T. Scidelo, *Synthèse expérimentale du projet PROJET_THERMIQUE_2*, résultats de segmentation, détection contextuelle et suivi temporel, ensemble de fichiers internes du projet. https://github.com/scideloandriasahy-bot/PROJET_THERMIQUE_2.

[48] Projet *PROJET_THERMIQUE_2*, interface de démonstration Streamlit. https://projetthermique2-4alljlvrbmd6npmnzjjksq.streamlit.app.

Appendice A

Compléments mathématiques

A.1 Probabilité d'absorption à horizon fini

Le chapitre 11 utilise une chaîne dont la sous-matrice transitoire est Q et la matrice de passage vers les états absorbants est R. Comme les lignes de la matrice complète somment à un,

$$R\mathbf{1} = \mathbf{1} - Q\mathbf{1}. \tag{A.1}$$

La somme des probabilités d'absorption pendant les h prochains pas est alors

$$\sum_{k=0}^{h-1} Q^k R\mathbf{1} = \sum_{k=0}^{h-1} (Q^k - Q^{k+1})\mathbf{1} \tag{A.2}$$

$$= (I - Q^h)\mathbf{1}. \tag{A.3}$$

Après pondération par la distribution présente et ajout de la masse déjà critique, on retrouve l'équation (11.7). Cette démonstration fait apparaître le rôle de la masse absorbée initiale et évite une renormalisation incorrecte des seuls états transitoires [2].

A.2 Récurrence de fin de segment d'un HSMM

Une formulation de durée explicite distingue la fin d'un segment et l'état occupé à l'instant courant. Si $g_j(d)$ est la loi de durée de l'état j, A_{ij} la transition entre états distincts, π_j la probabilité initiale et $b_j(\mathbf{y}_u)$ la vraisemblance de l'observation, une récurrence de fin de segment est

$$a_t(j) = \sum_{d=1}^{\min(D_{\max},t)} g_j(d) \prod_{u=t-d+1}^{t} b_j(\mathbf{y}_u) \left[\mathbf{1}_{d=t}\pi_j + \mathbf{1}_{d<t} \sum_{i \neq j} a_{t-d}(i) A_{ij} \right]. \tag{A.4}$$

Le terme $d = t$ initialise un segment commençant au premier instant. Pour un filtrage en ligne, il faut aussi traiter le segment courant qui peut être inachevé. Les probabilités de fin de segment ne sont donc pas, à elles seules, le posterior de l'état courant [15].

A.3 Équation thermique de référence

Pour une perspective de modélisation guidée par la physique, l'équation volumique de chaleur s'écrit

$$\rho c_p \frac{\partial T}{\partial t} = \nabla \cdot (k \nabla T) + q_v. \tag{A.5}$$

q_v est une puissance par unité de volume. Une puissance totale en watts ne se substitue pas directement à ce terme. La géométrie, les propriétés des matériaux, les conditions initiales et les échanges aux frontières sont nécessaires avant toute résolution.

Appendice B

Annexes expérimentales : lecture d'une projection

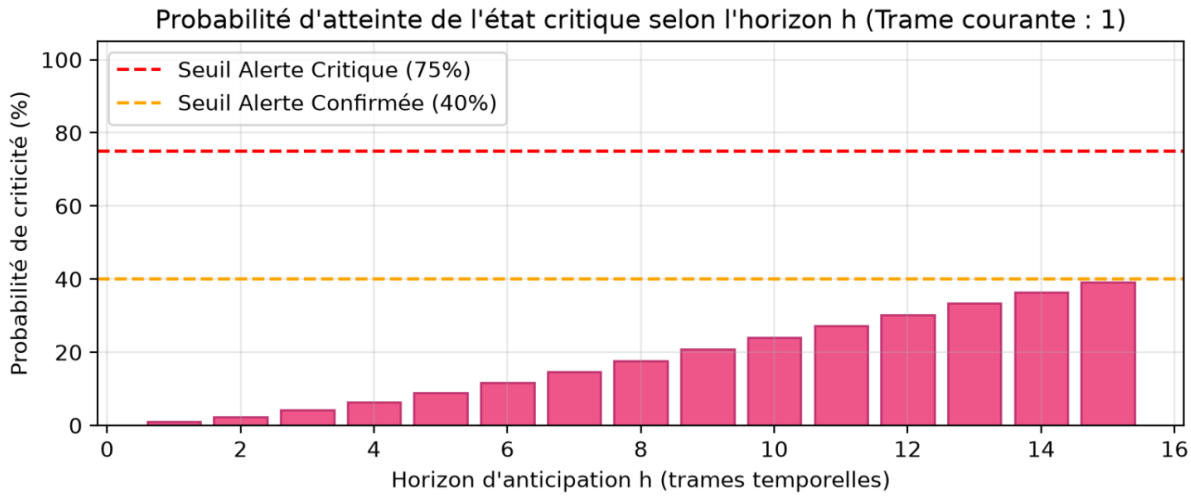

Figure B.1 : Projection du risque depuis un état courant. Les barres représentent un premier passage à différents horizons ; les lignes pointillées sont des seuils de décision. Exemple d'affichage du projet [**?**].

Cette représentation complète les courbes par état initial du chapitre 11. Les deux lectures ne doivent pas être confondues : l'une compare des départs déterminés, l'autre conditionne la projection par l'état estimé à l'instant choisi. Les seuils représentés sont des paramètres d'interface, non des limites industrielles universelles.

Glossaire

Absorption
Atteinte d'un état dont la chaîne de projection ne sort plus. Elle sert ici à représenter l'événement de premier passage critique.

Abstention
Choix de ne pas produire une décision catégorique lorsque les observations ou le niveau de confiance sont insuffisants.

Annotation
Information de référence associée à une image, à un pixel ou à une séquence. Sa définition détermine la tâche évaluée.

Calibration probabiliste
Accord entre confiance annoncée et fréquence de réussite observée sur des situations comparables.

Calibration radiométrique
Relation instrumentale permettant de relier un signal à une grandeur radiative ou à une température sous des conditions définies.

Champ de Markov
Modèle de dépendances locales entre variables, utilisé ici pour la cohérence des étiquettes de pixels voisins.

Classification
Attribution d'une classe à une observation, par exemple une combinaison d'état du roulement et de charge.

Contexte
Conditions de fonctionnement utiles à l'interprétation : charge, régime, ambiance ou identité de la machine.

Descripteur
Mesure ou représentation extraite d'une observation pour alimenter un modèle de décision ou de suivi.

Émissivité
Aptitude d'une surface à émettre un rayonnement thermique, relativement au corps noir dans des conditions comparables.

État caché
État du modèle qui n'est pas mesuré directement et doit être estimé à partir des observations.

Filtrage
Estimation de l'état présent à partir du passé et des observations disponibles au présent.

Fuite de données
Utilisation directe ou indirecte, lors de l'apprentissage ou du réglage, d'informations qui devraient rester réservées à l'évaluation.

Généralisation
Capacité à produire des résultats utiles sur des observations nouvelles, dans un domaine défini.

Horizon
Nombre de pas dans le futur considéré pour une projection. Son unité dépend de la cadence du modèle.

Incertitude
Limitation de la confiance liée aux observations, aux paramètres, au modèle ou à un changement de domaine.

Internet des objets (IoT)
Cadre de connexion des équipements et de transmission des observations. Dans ce mémoire, il désigne la perspective d'intégration de l'acquisition, du diagnostic et de la supervision.

Lissage temporel
Estimation d'un état passé pouvant utiliser des observations acquises après cet instant ; à distinguer du filtrage causal.

Masque
Carte spatiale désignant une région. Un masque de machine, de zone chaude et de défaut ne correspond pas à la même cible.

Premier passage
Premier instant où une trajectoire atteint un état ou un ensemble d'états donné.

ROI
Région d'intérêt sur laquelle les mesures ou le traitement sont concentrés.

Segmentation
Attribution d'une étiquette ou d'une probabilité à chaque pixel d'une image.

Séjour
Durée pendant laquelle le modèle demeure dans un état avant une transition.

Surapprentissage
Adaptation excessive aux particularités des données utilisées pour apprendre, au détriment de nouvelles observations.

Thermogramme
Représentation d'un signal infrarouge ou d'une température apparente, généralement visualisée à l'aide d'une palette.

Transfert d'apprentissage
Réutilisation d'une représentation apprise sur une tâche ou un ensemble de données pour une nouvelle tâche.

Validation groupée
Évaluation maintenant dans un même ensemble les observations appartenant au même essai, à la même séquence ou à la même machine.

Index alphabétique

Abstention, 57
Alerte, 57
AUPRC, 54
AUROC, 54

BNUT, 17

Calibration
    probabiliste, 50
Chaîne absorbante, 47
Classification hybride, 29
CNN, 26
Contexte de fonctionnement, 50

Délai de détection, 54
DenseNet121, 28
Descripteurs thermiques, 44
Déséquilibre des classes, 17
Dice, 53
Dropout, 27
Durée de séjour, 52

Émissivité, 9
Exactitude, 34

Filtrage temporel, 46

HMM, 46
HSMM, 52

ICM, 46
Incertitude, 51
Indicateur de santé, 44
Internet des objets, 2
IoU, 53

Jeux de données, 16

KNN, 30

Maintenance conditionnelle, 1
Maintenance prévisionnelle, 1
Matrice de confusion, 34
Matrice fondamentale, 47
Monte Carlo dropout, 51

MRF, 45

Potts (modèle de), 45
Premier passage, 2

Random Forest, 30

SVM, 29

Thermographie infrarouge, 8
Transfert d'apprentissage, 27

U-Net, 49

XGBoost, 30